Stéphane Gonzalez

Ingénieur IA
(AI Engineer)

LLM · RAG · MLOps

CONTACT

Poussan (34), France

06 61 18 43 71

gonzalezcourrier34@gmail.com

Portfolio
gonzalezcourrier34-glitch.github.io

GitHub
gonzalezcourrier34-glitch

LinkedIn
Stéphane Gonzalez

COMPÉTENCES

IA générative
LLM, RAG, agents LangGraph, fine-tuning QLoRA (SFT, DPO), vLLM, Mistral, RAGAS, juge LLM

ML et données
Python, PyTorch, scikit-learn, XGBoost, Optuna, SQL, PostgreSQL, pgvector, FAISS, Airflow

MLOps et déploiement
FastAPI, Docker, CI/CD GitHub Actions, Azure, MLflow, Evidently, Grafana, pytest

Conduite de projet
Cadrage, critères de succès, budget, RGPD

OUTILS

Hugging Face · LangChain · Milvus · ONNX · Angular · Ruff · Git

SAVOIR-ÊTRE

Écoute et conseil client : 16 ans de vente spécialisée

Pédagogie et vulgarisation

Rigueur : mesurer avant d'affirmer

Autonomie sur des projets complets

LANGUES

Français : langue maternelle

Anglais : B1 (CLES 1, 2012)

Espagnol : intermédiaire

Ingénieur IA, développeur de formation, je reviens à la technique après 16 ans de conseil client. Quatorze mois de formation pratique et onze projets concrets, dont SortirIA, mené seul de bout en bout jusqu'à la production, m'ont permis de concevoir, évaluer et déployer des solutions à base de LLM. C'est avec le même courage et la même détermination que je me sens aujourd'hui prêt à rejoindre votre entreprise et à m'y investir.

PROJETS IA

SortirIA · assistant IA de sorties, en production — **depuis oct. 2026**

- En ligne sur sortiria-montpellier.fr : assistant RAG de sorties autour de Montpellier, conçu et déployé seul (agent LangGraph de collecte nocturne, recherche hybride PostgreSQL + pgvector, réponses sourcées par Mistral, FastAPI et Angular sur Azure).
- Fixé les seuils avant de mesurer : 98,7 % des propositions conformes (seuil 95 %), 97,8 % de pertinence (seuil 70 %), juge LLM validé à 91,9 % sur 135 cartes nouvelles.
- Mis en place une évaluation qui bloque le déploiement en CI, un suivi Grafana et MLflow, pour environ 10 $ par mois.

Agent IA de triage médical · fine-tuning de LLM — **sept. – oct. 2026**

- Spécialisé Qwen3-1.7B (SFT puis DPO, QLoRA, 6 Go de GPU) pour trier les patients des urgences en P1, P2, P3 : 453 cas sur 500 bien classés, F1 macro 90,6 %.
- Suivi le sous-triage autant que le F1 (5,4 %), diagnostiqué puis corrigé un premier entraînement raté ; modèle servi par vLLM derrière une API FastAPI (P95 de 1,13 s).

Scoring crédit · MLOps — **avr. – mai 2026**

- Comparé quatre modèles et retenu XGBoost, réglé avec Optuna sur le coût métier (un défaut manqué coûte dix fausses alertes) : 85 % des défauts détectés.
- Exposé en API FastAPI, suivi dans MLflow et Evidently, latence P95 réduite de 18 % (9,2 ms).

Autres projets — **2025 – 2026**

- Agent d'échecs LangGraph vérifié par 1 029 tests · collecte multi-sources orchestrée par Airflow · RAG FAISS évalué avec RAGAS · vision semi-supervisée sur IRM.

EXPÉRIENCE PROFESSIONNELLE

Conseiller de vente, rayon informatique — **2009 – 2025**
Auchan Retail, Sète

- Conseillé des clients pendant 16 ans : analyse du besoin, explication de sujets techniques, gestion du rayon et des fournisseurs. En détachement de formation depuis 2025.

Développeur, puis chef de projet informatique — **1998 – 2006**
Montpellier et Tenerife

- Analyste programmeur SQL, Visual Basic, WinDev chez Alternative Informatique (1998 – 2001), chef de projet chez Spiral Informatique (2001 – 2002), informaticien indépendant à Tenerife (2002 – 2004), analyste programmeur en CDD chez Store System Services et Helios (2004 – 2006).

FORMATION

AI Engineer — **2025 – 2026**
OpenClassrooms · titre RNCP niveau 7 « Expert en ingénierie et science des données »

Licence en sciences de l'éducation, mention assez bien — **2011 – 2012**
Université Paul-Valéry

Diplôme d'État d'éducateur technique spécialisé — **2006 – 2009**
IRTS Montpellier

Développeur web — **2004**
AFPA

Technicien supérieur en informatique de gestion — **1997 – 1998**
AFPA

Baccalauréat C (mathématiques et sciences physiques) — **1994**