Stéphane Gonzalez

AI Engineer

CONTACT

Poussan (Hérault)
gonzalezcourrier34@gmail.com
Portfolio : gonzalezcourrier34-glitch.github.io
GitHub : gonzalezcourrier34-glitch
LinkedIn : Stéphane Gonzalez

COMPÉTENCES

LLM et IA générative
RAG, agents LangGraph, fine-tuning QLoRA (SFT, DPO), évaluation par juge LLM calibré

Machine Learning
Python, pandas, scikit-learn, LightGBM, PyTorch, Optuna, SHAP

Données
SQL, PostgreSQL, pgvector, Airflow, collecte multi-sources

Mise en production
FastAPI, Docker, CI/CD GitHub Actions, Azure, MLflow, Grafana, suivi de dérive

Conduite de projet
Cadrage, critères de succès, budget, RGPD

OUTILS

`Mistral` `LangChain` `vLLM` `Hugging Face` `FAISS` `Milvus` `Evidently` `ONNX` `Angular` `pytest` `Ruff` `Git`

SAVOIR-ÊTRE

Écoute et conseil client : 16 ans de vente spécialisée
Pédagogie et vulgarisation
Rigueur : mesurer avant d'affirmer
Autonomie sur des projets complets

LANGUES

Français : langue maternelle
Espagnol : intermédiaire
Anglais : B1 (CLES 1, certification universitaire, 2012)

Développeur de formation, revenu à la technique après seize ans de conseil client en informatique. Je conçois des solutions d'IA **de la donnée jusqu'au service en production** : RAG, agents, fine-tuning de LLM, API, CI/CD, cloud et monitoring. Je cherche un poste d'**AI Engineer** pour mettre en production des solutions à base de LLM, avec un goût marqué pour l'évaluation et le suivi en production.

PROJETS EN IA

SortirIA · projet personnel, en ligne · sortiria-montpellier.fr
Assistant de sorties pour Montpellier et le bassin de Thau : agent LangGraph de collecte nocturne, recherche hybride PostgreSQL + pgvector, réponses sourcées par Mistral, déploiement continu sur Azure, évaluation bloquante en CI, suivi de dérive.
98,7 % des propositions respectent la demande · ≈ 10 $ par mois la 1re année

Agent IA de triage médical
Qwen3-1.7B spécialisé par SFT puis DPO (QLoRA, 6 Go de GPU), servi par vLLM derrière une API surveillée.
453 / 500 cas bien classés · sous-triage 5,4 %

Chess Agent · CheckIt.AI · Assistant RAG OpenAgenda
Agent LangGraph avec RAG et LLM local (1 029 tests) ; moteur de collecte multi-sources orchestré par Airflow ; premier RAG évalué avec RAGAS.

Scoring crédit · TechNova · BrainScanAI
Modèles mis en production avec MLflow, Evidently et ONNX ; API en ligne, P95 de 9,2 ms après allègement des logs ; vision semi-supervisée sur IRM (rappel moyen 0,96 sur 5 découpages).

EXPÉRIENCE PROFESSIONNELLE

Conseiller de vente, spécialité informatique — 2009 – 2025
- Analyse du besoin client et conseil en matériel et solutions informatiques
- Explication de sujets techniques à un public non spécialiste

Analyste programmeur (CDD) — 2004 – 2006
Store System Services (2004 – 2005), puis Helios (2006), Montpellier

Informaticien indépendant — 2002 – 2004
Santa Cruz de Tenerife (Espagne)

Chef de projet informatique — 2001 – 2002
Spiral Informatique, Montpellier

Analyste programmeur SQL, Visual Basic, WinDev — 1998 – 2001
Alternative Informatique, Le Millénaire, Montpellier
- Développement d'applications de gestion et de bases de données

FORMATION

Ingénieur IA (AI Engineer) — 2025 – 2026
OpenClassrooms · 11 projets, du Machine Learning à la mise en production

Licence en sciences de l'éducation, mention assez bien — 2011 – 2012

Formation d'éducateur technique spécialisé (sur concours) — 2006 – 2009

Formation courte en développement web — 2004
AFPA

Technicien supérieur en informatique et administration — 1997 – 1998
AFPA

Baccalauréat C (mathématiques et sciences physiques) — 1994