PORTFOLIO • AI ENGINEER

Stéphane Gonzalez
AI Engineer

Reconverti, aujourd'hui je veux avoir une place active dans la conception de solutions d'intelligence artificielle, de la donnée jusqu'au service en production : fine-tuning de LLM, RAG, agents, API, CI/CD, cloud et monitoring.

Machine Learning | Deep Learning | LLM & fine-tuning | RAG & agents | MLOps | Cloud Azure

11
Projets IA menés

6
Projets avec CI/CD

Azure
SortirIA en production

90,6 %
Triage médical : cas bien classés

PROFIL

À propos

Développeur, éducateur de formation, puis conseiller. Aujourd'hui, AI Engineer.

Ancien développeur de formation (SQL, Visual Basic, WinDev), j'ai passé 16 ans dans le conseil de vente client en informatique, puis j'ai choisi de revenir à mes premiers amours : le développement et la technique. C'est dans ce sens que je me suis spécialisé dans l'intelligence artificielle avec la formation AI Engineer d'OpenClassrooms.

Mon parcours de formation m'a fait traverser les domaines de l'IA, du Machine Learning classique au déploiement d'API, puis au RAG, aux agents et au fine-tuning de LLM, toujours avec la même exigence : un système testé, reproductible et mesuré.

Aujourd'hui, mon **objectif professionnel** est de rejoindre une équipe comme AI Engineer pour concevoir et mettre en production des solutions à base de LLM, avec une attention particulière à l'évaluation et au monitoring.

Ma carte mentale

Ce portfolio est construit à partir de cette carte : chaque branche correspond à une section de la page.

Stéphane Gonzalez, AI Engineer

1. Profil

- Développeur, puis 16 ans de conseil client en informatique
- Formation Ingénieur IA, OpenClassrooms
- Objectif : AI Engineer, évaluation et monitoring

2. Projets

- SortirIA, projet personnel en ligne, avec son rapport
- Triage médical, Chess Agent, CheckIt.AI
- RAG OpenAgenda, scoring crédit et 5 autres
- 10 projets validés par OpenClassrooms

3. Compétences

- ML et données
- Deep Learning et LLM
- Développement et déploiement
- MLOps et cloud
- Conduite de projet

4. Réflexion

- Ce que j'ai appris
- Ce que je ferais différemment
- Progrès et défis restants
- Ma vision du métier
- Compétences en cours d'acquisition

5. Soft skills

- Esprit d'analyse
- Curiosité
- Communication
- Gestion de projet
- Relation client
- Créativité

Carte complète, avec chaque compétence reliée à ses preuves : format Freeplane / Xmind (.mm) · version texte

MES RÉALISATIONS

Mes projets

J'ai mené 11 projets pendant ma formation, présentés ici du plus récent au plus ancien. Dix sont des projets de formation, tous validés par OpenClassrooms ; le onzième, SortirIA, est mon projet personnel : il réunit les briques des précédents dans un service en ligne.

Tous sont des projets individuels. Pour chacun, je vous livre le code ou les livrables, et la carte précise mon rôle et la principale difficulté rencontrée.

Mon projet personnel • RAG • Agent • Production sur Azure Oct.-nov. 2026 · en ligne

SortirIA www.sortiria-montpellier.fr

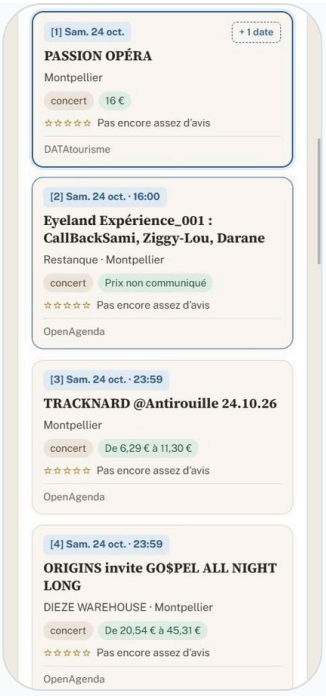
Pour mon projet personnel, j'ai choisi de créer un assistant de sorties pour Montpellier et le bassin de Thau. L'idée : écrire sa demande comme on la dirait (« un concert gratuit ce week-end à Sète ») ; SortirIA répond avec des sorties qui respectent la date, le lieu, le public et le budget. Chaque nuit, un agent LangGraph collecte et vérifie les agendas ouverts (OpenAgenda, DATAtourisme ; le programme PDF de Sète est lu depuis mon poste) ; la recherche combine filtres SQL, mots et vecteurs (pgvector) et Mistral rédige la réponse. Le service est en ligne sur Azure, déployé à chaque push et surveillé.

Mon rôle	Tout, du cadrage au suivi en production. J'ai aussi écrit moi-même aux sources pour demander l'autorisation de collecter leurs agendas.
Le défi	Respecter à coup sûr la date, le lieu, le public et le budget d'une demande écrite librement, avec des agendas hétérogènes à collecter et vérifier chaque nuit.

Comment	Des règles comprennent la demande (date, lieu, public, budget) et des filtres SQL la font respecter. Les mots et le sens servent ensuite à classer ce qui reste. Mistral rédige uniquement à partir des fiches trouvées.
Pourquoi ce choix	Des règles pour comprendre la question : 100 % de compréhension sur mon jeu de test, en 1 ms et gratuitement, là où un petit modèle ajoutait coût et délai. PostgreSQL avec pgvector plutôt que FAISS : filtres stricts et recherche par le sens tiennent dans la même requête.



L'accueil : on écrit sa demande comme on la dirait.



La réponse : des cartes datées, avec prix et source citée.

MES RÉSULTATS ÉVALUÉS

98,7 %
Contraintes respectées

97,8 %
Pertinence des 3 premières sorties

91,9 %
Accord du juge LLM avec l'humain, sur 135 cartes nouvelles

6,4 s
Temps de réponse P95 (mesuré depuis un poste ; 4,1 s en production le 2/11)

0,12 $
Coût Mistral pour 1 000 questions

Limite et ouverture

Sur 93 questions de vrais testeurs, 47 % de réponses exactes : ils cherchaient aussi des lieux permanents, alors que mes agendas recensent des événements datés. J'en ai fait ma priorité : élargir les sources. Je démarche des lieux partenaires (Sète, Frontignan), et chaque lundi, l'agent me propose les agendas à ajouter.

CONDUITE DE PROJET

1. Besoin

Trouver une sortie qui convient vraiment (date, lieu, public, budget), en un seul endroit, plutôt que dans dix agendas.

2. Audit des données

Seulement des sources ouvertes et autorisées. Chaque fiche est vérifiée, dédoublonnée et attribuée à sa source.

3. Solution

Un agent LangGraph la nuit, PostgreSQL et pgvector, FastAPI, Angular, Mistral. J'ai repris et adapté le code de mes projets précédents.

4. Aide à la décision

J'ai fixé les seuils avant de mesurer : 95 % de contraintes respectées, 70 % de pertinence. Le juge est calibré sur l'humain. Puis j'ai mesuré l'usage réel : 93 questions de testeurs, 47 % de réponses exactes. La couverture des sources devient ma priorité.

5. Contrôle

Environ 10 $ par mois la première année. L'évaluation est rejouée en CI, et le déploiement est bloqué sous 95 %. Grafana, MLflow, dérive suivie chaque nuit (PSI) et chaque mois (Evidently), alertes et budget Azure.

LE MLOPS DE SORTIRIA

La consigne du projet final propose quatre thèmes MLOps. SortirIA s'appuie sur Mistral plutôt que sur un modèle entraîné maison. J'ai donc adapté chaque thème à ce cas.

Cycle de vie des modèles

Couvert

À chaque push, la CI lance les tests sur une vraie base PostgreSQL et rejoue l'évaluation de la recherche. Sous 95 % sur mes 50 questions principales (90 % pour deux jeux annexes), le déploiement est bloqué. Sinon, le service part sur Azure. Ensuite, un contrôle vérifie toutes les 3 heures qu'il répond toujours. Sur mon poste, MLflow garde la trace de chaque évaluation et de chaque collecte.

Suivi de la dérive

Couvert

Chaque nuit, je compare les 7 derniers jours aux 28 précédents (PSI). Je surveille trois choses : ce que les visiteurs demandent, ce que SortirIA leur répond, et ce que les sources apportent. Le lundi, je reçois un rapport. Si la dérive est forte, une alerte part. Tout se lit dans Grafana.

Une fois par mois, GitHub Actions produit un rapport Evidently complet. La base s'ouvre le temps du rapport, puis se referme. Quand les données sont trop peu nombreuses, le rapport le signale et attend d'en avoir assez.

Réentraînement automatique

Adapté

Ici, l'amélioration passe par l'agent du lundi plutôt que par un réentraînement. Il lit les recherches ratées et les pouces bas, puis ouvre une pull request par correction : un synonyme à ajouter, un agenda à lire. La CI la teste, je la valide, elle part en production. Le fine-tuning viendra quand j'aurai assez d'avis réels.

Versionnage des données et des modèles

Couvert

Mes 8 consignes sont versionnées dans MLflow. La chaîne complète aussi : modèles Mistral, versions des consignes, empreintes des 10 jeux d'évaluation. Deux étiquettes, « production » et « précédente », me permettent de revenir en arrière. La CI exige une nouvelle version pour toute consigne modifiée, et chaque réponse garde la trace de la sienne. Mes jeux de test pèsent environ 1 Mo : Git suffit à les versionner.

> **Prochaine étape :** MLflow tourne aujourd'hui sur mon poste. Je le déploierais à côté du service, pour suivre directement la production.

LangGraph · Mistral · PostgreSQL / pgvector · FastAPI · Angular · Azure Container Apps · GitHub Actions · Grafana · MLflow · Evidently · Airflow

Mesures détaillées → **Site en ligne →** **Code →** **Rapport de conduite de projet →**

Rapport en PDF → Dossier du projet → Documentation →

LLM • Fine-tuning • Production

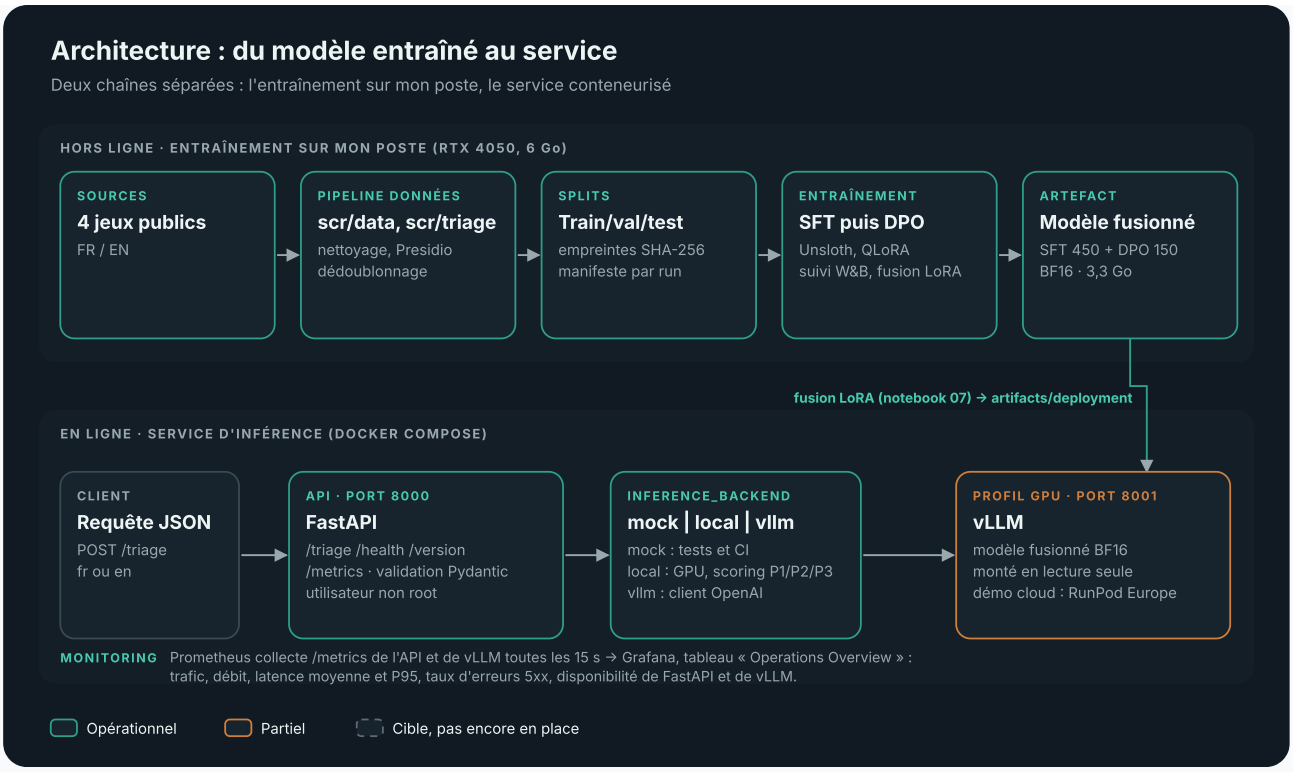
Sept.-oct. 2026 · ✓ Validé

Agent IA de triage médical

J'ai spécialisé un petit modèle de langage, Qwen3-1.7B, pour classer un patient des urgences en P1, P2 ou P3. Il justifie sa décision, en français comme en anglais. Je l'ai entraîné par SFT puis DPO, avec QLoRA, sur une carte graphique de 6 Go. Il est servi par vLLM, derrière une API FastAPI journalisée et surveillée.

Mon rôle	Tout le projet, sur mon ordinateur portable (GPU de 6 Go) puis un GPU cloud (RunPod) : audit et anonymisation des données, entraînement, mise en service, tests et documentation.
Le défi	Tenir sur une carte de 6 Go en gardant les urgences bien classées. Mon premier entraînement, sur Qwen3-Base, a échoué. J'ai cherché pourquoi, puis je l'ai corrigé.

Comment	Je change une seule chose à la fois, depuis un essai à trois changements qui m'avait fait perdre le fil. J'ai donné plus de poids à la priorité P1/P2/P3 dans l'apprentissage : le modèle a ainsi appris la décision, et plus seulement le texte. Quand la Base a eu du mal à finir ses réponses, j'ai mesuré avant de corriger : il lui manquait l'apprentissage du jeton de fin.
Pourquoi ce choix	J'ai entraîné les deux versions de Qwen3, la Base et l'Instruct, avec le même pipeline. Au même niveau global, la Base sous-trie moins : 5,4 % contre 7,2 %. C'est elle que je livre.



Chaque brique est marquée opérationnelle ou partielle : c'est l'état réel du projet.

MES RÉSULTATS ÉVALUÉS

453 / 500 Cas du test gelé bien classés	**90,6 %** F1 macro	**93,4 %** Urgences P1 reconnues
5,4 % Sous-triage	**1,13 s** Latence P95	

Limite et ouverture

5,4 % de sous-triage : c'est pourquoi je le présente comme un second avis, avec une grille go / no-go et un pilote en quatre phases. Pour aller plus loin : repartir de la Base dès le début et garder le test intact jusqu'au bout, pour une mesure encore plus fiable.

CONDUITE DE PROJET

1. Besoin

Aider les infirmiers d'accueil à trier les patients, avec une explication.

2. Audit des données

164 477 lignes publiques auditées, anonymisées (Presidio), réduites à 5 000 cas équilibrés.

3. Solution

QLoRA, SFT puis DPO, modèle fusionné et servi par vLLM.

4. Aide à la décision

Grille go / no-go et pilote en quatre phases, le modèle en second avis.

5. Contrôle

4 semaines, 6 Go de GPU, CI avec 40 tests, test gelé rejoué sur le modèle servi.

Qwen3 · PyTorch · QLoRA · SFT / DPO · vLLM · FastAPI · Prometheus / Grafana · W&B · GitHub Actions

Journal des expériences → **Code →** **Documentation →** **Rapport technique →**

Agent IA • RAG

Août 2026 · ✓ Validé

Chess Agent

Un assistant pour apprendre les ouvertures d'échecs. Un agent LangGraph combine Stockfish, Lichess, un RAG sur Wikichess et un LLM local. Il explique une position en français.

Le défi

Empêcher le LLM d'inventer un coup ou une évaluation. J'ai réparti les rôles : Stockfish calcule, les sources donnent le contexte, le LLM se contente d'expliquer.

Comment

Chaque outil a un seul rôle : Stockfish calcule, Lichess et Wikichess donnent le contexte, le LLM explique. 34 cas testés vérifient que l'agent envoie chaque question vers la bonne étape.

Pourquoi ce choix

Un moteur d'échecs calcule juste à coup sûr ; un LLM explique bien. J'ai donc confié à chacun ce qu'il fait le mieux, et les 34 cas de routage le vérifient.

MES RÉSULTATS ÉVALUÉS

34 / 34 Cas de routage de l'agent validés	90,4 % Couverture du code mesurée
1 029 Tests automatisés	

Limite et ouverture

Je teste aujourd'hui le code et le routage. Prochaine étape : mesurer aussi la qualité des explications, avec un jeu de positions annotées et un juge calibré sur l'humain, comme dans SortirIA.

LangGraph · Milvus · Ollama · FastAPI · MongoDB · Angular

Qualité et tests → **Code →** **Documentation →**

Data engineering

Juillet 2026 · ✓ Validé

CheckIt.AI

Un moteur de collecte que je peux réutiliser. Chaque type de source a son moteur, chaque fournisseur son adaptateur et sa configuration YAML. Les articles sont validés, dédoublonnés et contrôlés, le tout orchestré par Airflow. Premier usage : le fact-checking. SortirIA le réutilise aujourd'hui.

Le défi

Faire entrer des sources très différentes dans un même format fiable : dates, liens et images vérifiés, doublons écartés. Le tout avec un seul code, réutilisé pour chaque source.

Comment

Un moteur par type de source (RSS, API, web…), et pour chaque fournisseur, un adaptateur et un fichier YAML. Ajouter une source demande très peu de code. Chaque lot passe un contrôle qualité qui s'arrête en erreur si quelque chose cloche.

Pourquoi ce choix

Un moteur par type de source se réutilise : ce même moteur collecte aujourd'hui les agendas de SortirIA.

MES RÉSULTATS ÉVALUÉS

21 Sources branchées	4 518 Articles collectés en un passage
99,1 % Articles valides après contrôle qualité	1 319 Images téléchargées et vérifiées

Limite et ouverture

Au premier lot, j'ai repéré de nombreux articles à l'URL canonique manquante, et les images sont vérifiées sur le plan technique. Prochaine étape : transformer ces mesures en règles de rejet, puis analyser le contenu des images, utile pour le fact-checking.

Airflow · PostgreSQL · YAML · Docker · Streamlit

Résultats du pipeline → **Code →** **Documentation →**

Reinforcement Learning

Juillet 2026 · ✓ Validé

Atterrissage LunarLander

J'ai entraîné deux agents, DQN et PPO, à poser un module lunaire. J'ai optimisé leurs hyperparamètres, puis présenté les résultats dans une API et un tableau de bord.

Le défi

Obtenir un atterrissage stable, et pouvoir le reproduire. J'ai comparé DQN et PPO, puis réglé leurs hyperparamètres avec Optuna.

Comment

J'ai d'abord mesuré un agent aléatoire, pour avoir une référence. Optuna a testé 10 combinaisons de réglages pour chaque algorithme. Puis j'ai évalué chaque agent sur 100 atterrissages, pour une moyenne fiable.

Pourquoi ce choix

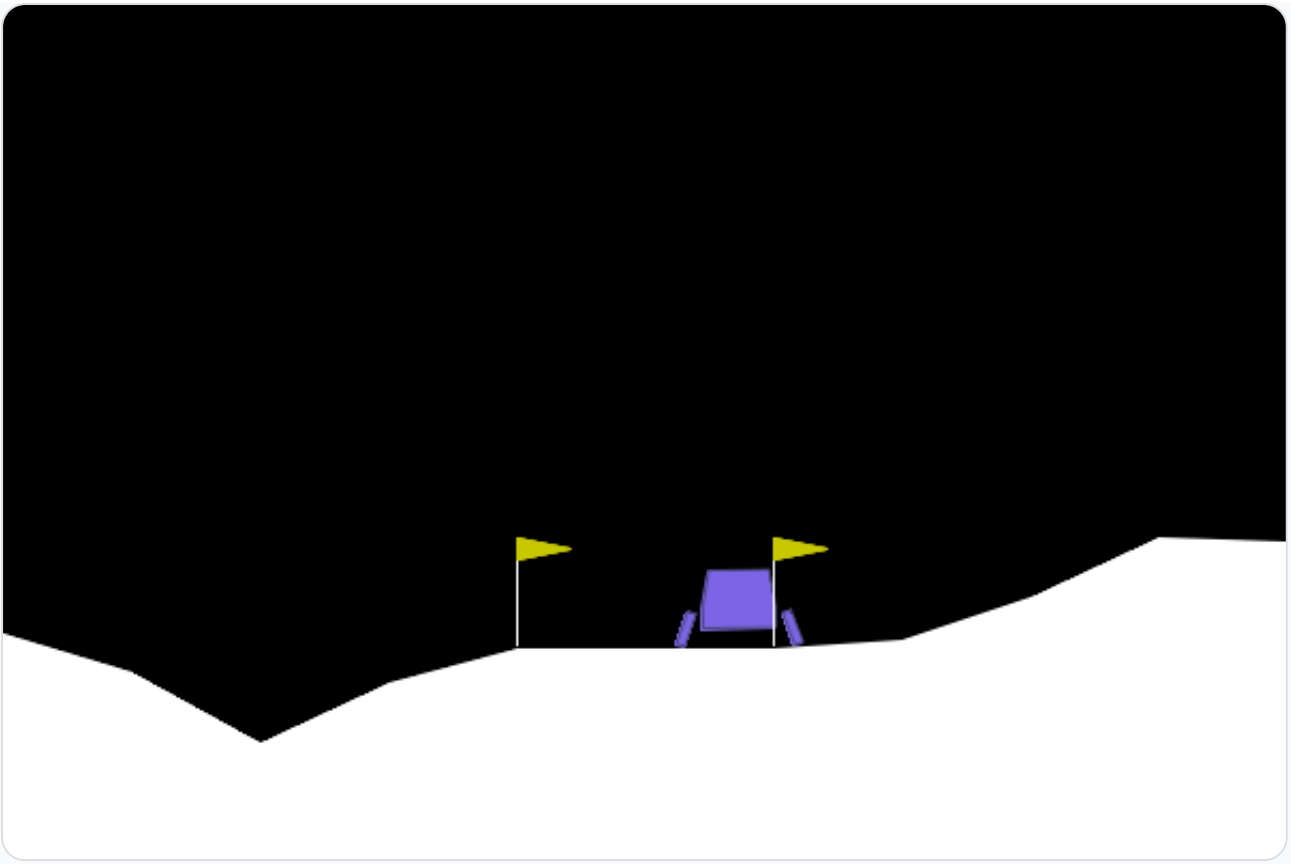
PPO l'emporte nettement : 270,6 de récompense moyenne contre 119,9 pour DQN, avec un écart-type de 27,7 qui montre des atterrissages réguliers.

MES RÉSULTATS ÉVALUÉS

270,6 Récompense moyenne PPO sur 100 épisodes (objectif : 200)	**± 27,7** Écart-type : des atterrissages réguliers
119,9 DQN, même évaluation	**-192,4** Agent aléatoire, la référence

Limite et ouverture

Une seule seed et 10 essais Optuna : PPO gagne ici, mais il faut le confirmer. Prochaine étape : relancer sur plusieurs seeds, comme je l'avais fait sur CurelyticsIA avec 5 découpages des données.



Un atterrissage réussi par l'agent entraîné · voir l'animation (9 s)

Stable-Baselines3 Gymnasium Optuna FastAPI

Analyse des résultats → **Code →**

Vision • Semi-supervisé

Juin 2026 · ✓ Validé

CurelyticsIA · BrainScanAI

Détecter des tumeurs sur des IRM cérébrales, avec très peu d'images annotées. J'ai extrait les caractéristiques avec un ResNet50, regroupé les images (ACP et clustering), créé des pseudo-étiquettes, puis entraîné un ResNet18. J'ai aussi chiffré le projet pour un budget de 5 000 €.

Le défi

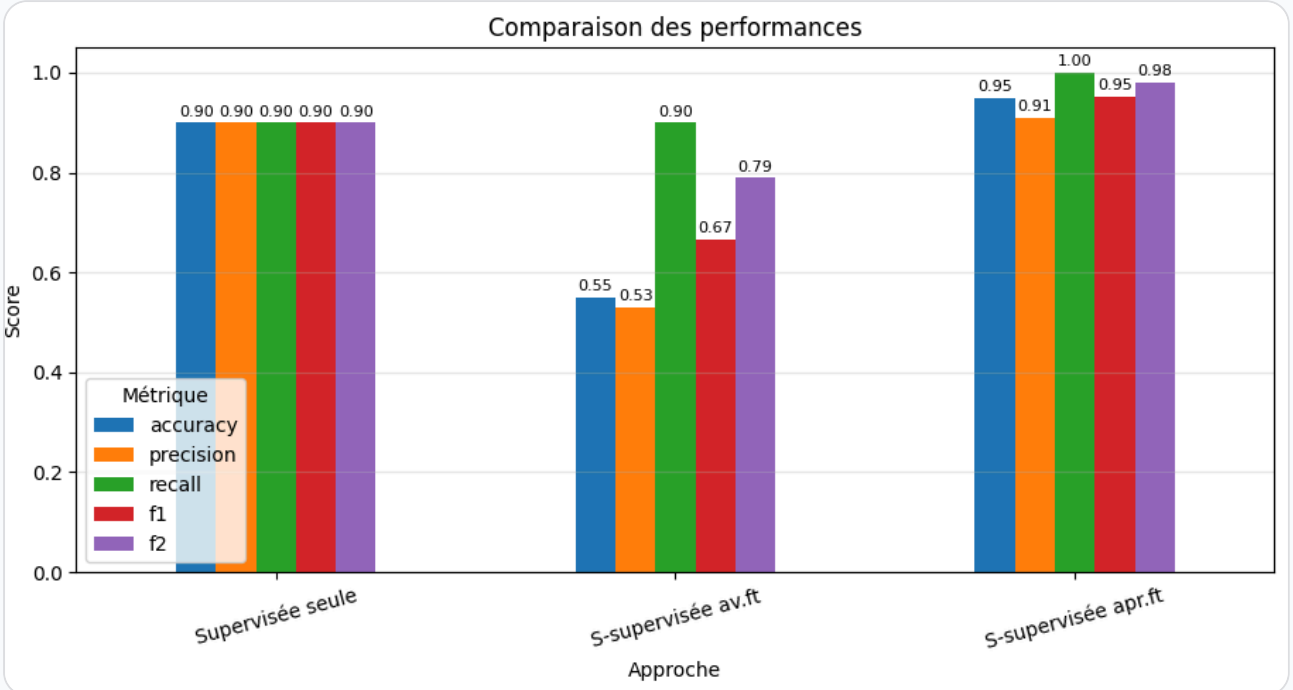
Apprendre avec très peu d'exemples, en repérant chaque tumeur. Ici, le rappel passe avant tout.

Comment

Je garde les pseudo-étiquettes les plus sûres : un score de confiance, moitié cluster, moitié distance, avec un seuil à 0,681. J'entraîne un ResNet18 dont seules les dernières couches sont réentraînées, puis je compare les deux approches sur 5 découpages différents des données. Je suis le F2, qui compte deux fois plus le rappel.

Pourquoi ce choix

Quand annoter une IRM coûte cher, les pseudo-étiquettes permettent d'apprendre avec peu d'exemples. J'ai mesuré leur apport honnêtement : sur 5 découpages, les deux approches détectent autant de tumeurs (rappel moyen de 0,96). Mon étude du budget d'annotation, dans le même notebook, mesure ensuite l'apport selon le nombre d'images annotées.



Supervisé seul, puis semi-supervisé avant et après fine-tuning.

MES RÉSULTATS ÉVALUÉS

1,00 Rappel (tumeurs détectées), test principal	**0,98** F2-score, test principal
0,96 Rappel moyen sur 5 découpages des données	

Limite et ouverture

Mon jeu de test compte 20 images : une erreur y pèse 5 %, et les scores varient selon le découpage. Prochaines étapes : un test plus large, et choisir le modèle directement sur le F2 de validation plutôt que sur la perte.

PyTorch · ResNet · Clustering · Pseudo-labels

Notebook → **Code →**

Cadrage • Gestion de projet

Mai 2026 · ✓ Validé

Cadrage du PoC Fashion-Insta

J'ai cadré un système de recommandation de vêtements à partir de photos, pour une enseigne de mode. J'ai défini le besoin métier et choisi l'approche (CLIP et recherche vectorielle). J'ai planifié 3 semaines, chiffré le budget entre 13 et 15 k€ et fixé les KPI. J'ai aussi dessiné l'architecture cible sur Azure, estimé le ROI et traité le RGPD.

Mon rôle	Chef de projet IA : j'ai cadré, chiffré, puis présenté le projet au client.
Le défi	Permettre au client de décider avant d'écrire une ligne de code. KPI, budget, planning et RGPD étaient fixés pour un go / no-go.

Comment	J'ai fixé les critères de succès avant tout (Top-5 ≥ 75 %, Precision@5 ≥ 70 %). Puis j'ai découpé le projet en PoC, MVP et produit final, chacun avec son budget, en gardant 10 à 15 % de marge pour les imprévus.
Pourquoi ce choix	CLIP relie l'image et le texte dans un même espace : on retrouve un vêtement à partir d'une simple photo, ce qui répond directement au besoin d'inspiration visuelle.

MES LIVRABLES CHIFFRÉS

13 à 15 k€ Budget du PoC (3 semaines)	**163 à 207 k€** Programme complet, du PoC au produit
≥ 75 % Seuil go / no-go : Top-5 accuracy	**+480 k€** Résultat cumulé projeté en 2028

Limite et ouverture	Ce projet était un cadrage : mes chiffres sont des estimations, prêtes à être confrontées au réel. La suite logique : lancer le PoC sur 3 semaines, après une relecture croisée du budget.

Cadrage · Budget & ROI · Architecture Azure · RGPD · CLIP

Livrable : présentation de 52 diapositives

ML • MLOps

Avril-mai 2026 · ✓ Validé

Scoring crédit Prêt à dépenser

Un modèle de scoring crédit mis en production. Je l'ai exposé en API, j'ai suivi les expériences dans MLflow, surveillé la dérive avec Evidently et mesuré l'apport d'ONNX sur l'inférence.

Le défi

Garder le modèle fiable une fois déployé. Chaque appel est tracé, la dérive est détectée, et je sais où part le temps de réponse.

Comment

Un défaut de paiement manqué coûte 10 fois plus qu'une fausse alerte. J'ai donc choisi le seuil en validation croisée avec un F-bêta à β = 3, qui privilégie fortement le rappel. J'ai mesuré ONNX : à peine 2 % de gain, le goulot était ailleurs. C'est en allégeant les logs que l'API a gagné 18 % sur sa P95.

Pourquoi ce choix

J'ai comparé quatre modèles (régression logistique, Random Forest, XGBoost, CatBoost) sur le rappel et le F-bêta. XGBoost a été retenu, puis réglé avec Optuna, chaque essai suivi dans MLflow.

MES RÉSULTATS ÉVALUÉS

85,0 % Défauts de paiement détectés (rappel, jeu de test)	**0,76** AUC ROC sur le jeu de test
9,2 ms Latence API P95, après allègement des logs	**-18 %** Latence P95 gagnée en allégeant les logs

Limite et ouverture

Environ 6 alertes sur 7 sont des faux positifs : c'est le prix pour détecter 85 % des défauts. Pour aller plus loin : optimiser directement le coût métier, et enregistrer le seuil avec le modèle pour que l'API et le notebook utilisent le même.

XGBoost · CatBoost · MLflow · Evidently · ONNX · GitHub Actions

Notebook → **Code →**

LLM • RAG

Mars-avril 2026 · ✓ Validé

Assistant RAG OpenAgenda

Un assistant qui recommande des événements culturels, avec une recherche par le sens dans FAISS. Il classe les résultats en expliquant pourquoi, et Mistral rédige la réponse.

Le défi

Comprendre une demande libre, parfois floue. Et répondre uniquement avec les événements trouvés.

Comment

Je filtre d'abord par ville, date et type, avant toute recherche par le sens. Quand la recherche revient vide, l'assistant le dit franchement. Je l'ai testé avec RAGAS sur trois sortes de questions : claires, ambiguës et hors sujet.

Pourquoi ce choix

Le préfiltrage garantit la ville et la date ; la recherche par le sens classe ensuite. Résultat : 0,90 de précision du contexte retrouvé, et 100 % des questions hors sujet refusées.

MES RÉSULTATS ÉVALUÉS

1,00 Fidélité aux sources (RAGAS, questions claires)	**0,90** Précision du contexte retrouvé
100 % Questions hors périmètre refusées	**0,69** Rappel du contexte

Limite et ouverture

Des réponses encore peu ciblées (pertinence de 0,20), mesurées sur 9 questions. C'est ce qui m'a guidé pour SortirIA : des jeux d'évaluation plus larges, rejoués à chaque push, et un juge calibré sur l'humain.

LangChain · FAISS · Mistral · RAGAS · Docker

Notebook d'évaluation → **Code →**

ML • Déploiement

Février 2026 · ✓ Validé

TechNova Partners

Prédire le départ des employés. J'ai déployé le modèle dans une API FastAPI sécurisée, avec une base PostgreSQL qui trace chaque prédiction. L'API est en ligne.

Le défi

Rendre le modèle utilisable en production. L'API reçoit des données déjà préparées, et chaque prédiction est enregistrée en base.

Comment

J'ai choisi le F2-score, parce que rater un départ coûte plus qu'une fausse alerte, et cherché le seuil en validation croisée, sur l'entraînement seulement. La préparation des données tourne à part : des scripts remplissent des tables « clean », et l'API se concentre sur l'essentiel : lire, prédire et tracer.

Pourquoi ce choix

Sur le jeu de test, XGBoost détecte le plus de départs : un rappel de 0,81, contre 0,75 pour la régression logistique et 0,67 pour le Random Forest, avec le meilleur F2 (0,71).

MES RÉSULTATS ÉVALUÉS

80,6 % Départs détectés (rappel, XGBoost)	**0,71** F2-score, contre 0 pour un modèle naïf
0,85 AUC ROC sur le jeu de test	**47,5 %** Précision des alertes

Limite et ouverture

Une alerte sur deux est un faux positif, un choix assumé pour détecter presque tous les départs. Pour aller plus loin : présenter la régression logistique, presque aussi bonne et plus simple, à côté de XGBoost, pour que le métier choisisse en connaissance de cause.

scikit-learn · FastAPI · PostgreSQL · Hugging Face Spaces

Notebook → **Code →** **API en ligne →**

Vision • Segmentation

Oct.-nov. 2025 · ✓ Validé

ModeTrends

J'ai segmenté les vêtements sur des photos d'influenceurs avec un modèle Hugging Face, appelé par API. Puis j'ai analysé les tendances par type de vêtement.

Le défi

Juger un modèle conçu par d'autres. En mesurant l'IoU et le Dice vêtement par vêtement, j'ai vu que les petits éléments, chaussures et bras, sont mal segmentés.

Comment

J'ai comparé deux moyennes : sur les classes présentes, et pondérée par la surface. L'écart entre les deux montre que le modèle réussit les grandes zones mais rate les petites : chaussures, bras, accessoires.

Pourquoi ce choix

La moyenne globale donnait une bonne note au modèle ; la mesure classe par classe a révélé ses vrais points faibles, et donc où l'améliorer.

MES RÉSULTATS ÉVALUÉS

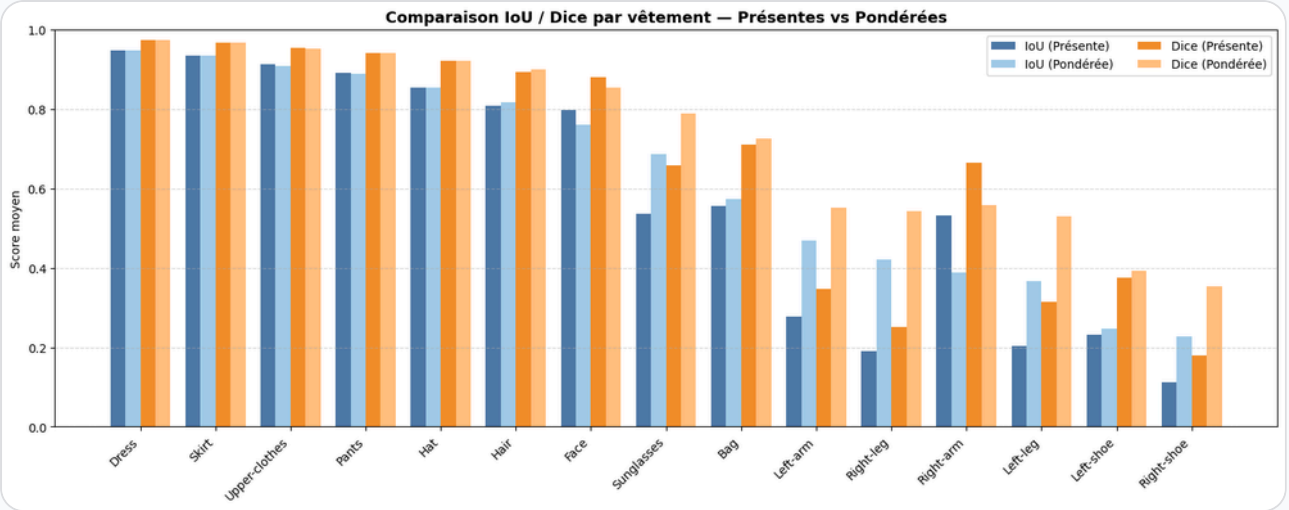
≈ 0,95
IoU sur les robes

≈ 0,93
IoU sur les jupes

≈ 0,11 à 0,23
IoU sur les chaussures : le point faible

Limite et ouverture

Les petits éléments (chaussures, bras) restent mal segmentés. Pour aller plus loin : enrichir les données en accessoires et rééquilibrer les classes rares, comme je l'ai noté dans mon notebook. Et toujours livrer un notebook exécuté, avec ses résultats visibles.



Qualité de la segmentation, vêtement par vêtement.

Hugging Face API | pandas | Matplotlib

Notebook → **Code →**

AUTO-ÉVALUATION

Compétences

Chaque niveau est mon auto-évaluation. Chaque compétence renvoie aux projets où je l'ai mise en pratique.

Notions — En progression — Opérationnel — Autonome

Machine Learning & données

Python — Autonome

Scoring crédit · Chess Agent · Triage médical · SortirIA

pandas / NumPy — Opérationnel

Scoring crédit · CurelyticsIA · CheckIt.AI

scikit-learn, XGBoost, CatBoost — Opérationnel

TechNova · Scoring crédit

SQL, PostgreSQL, pgvector — Opérationnel

TechNova · Scoring crédit · CheckIt.AI · SortirIA

Optuna, SHAP — Opérationnel

TechNova · Scoring crédit · LunarLander

Deep Learning & LLM

PyTorch — Opérationnel

CurelyticsIA · Triage médical

Hugging Face Transformers, PEFT — Opérationnel

Triage médical

Fine-tuning LoRA / QLoRA, SFT, DPO — Opérationnel

Triage médical

RAG : LangChain, FAISS, Milvus, pgvector, RAGAS — Opérationnel

RAG OpenAgenda · Chess Agent · SortirIA

Évaluation des LLM : juge LLM calibré sur l'humain, kappa, AC1 — Opérationnel

RAG OpenAgenda · SortirIA

Agents : LangGraph — Opérationnel

Chess Agent · SortirIA

Vision : CNN, OpenCV, segmentation — Opérationnel

CurelyticsIA · ModeTrends

Reinforcement Learning : Stable-Baselines3 — Opérationnel

LunarLander

Anonymisation : Presidio — Opérationnel

Triage médical

TensorFlow — Notions

Prochaine étape : je l'apprends pour reprendre des projets existants

Développement & déploiement

FastAPI — Opérationnel

TechNova · Scoring crédit · RAG OpenAgenda · Chess Agent · Triage médical · SortirIA

Docker, Docker Compose — Opérationnel

TechNova · Scoring crédit · RAG OpenAgenda · CheckIt.AI · Chess Agent · Triage médical · SortirIA

Tests et qualité : pytest, ruff, pyright, mypy — Opérationnel

Scoring crédit · CheckIt.AI · Chess Agent · Triage médical · SortirIA

Streamlit — Opérationnel

TechNova · Scoring crédit · RAG OpenAgenda

vLLM — Opérationnel

Triage médical

Angular — Opérationnel

Chess Agent · SortirIA

MLOps & cloud

CI/CD : GitHub Actions — Opérationnel

TechNova · Scoring crédit · RAG OpenAgenda · Chess Agent · Triage médical · SortirIA

MLflow — Opérationnel

Scoring crédit · SortirIA

Weights & Biases — Opérationnel

Triage médical

Airflow — Opérationnel

CheckIt.AI · SortirIA

Monitoring et dérive : Evidently, PSI, Prometheus, Grafana — Opérationnel

Scoring crédit · Triage médical · SortirIA

ONNX Runtime — Opérationnel

Scoring crédit

GPU cloud (RunPod), Hugging Face Spaces — Opérationnel

TechNova · Triage médical

Cloud IA managé : Azure ML, SageMaker, Vertex AI — Notions

Prochaine étape : Azure ML, dans la continuité de SortirIA sur Azure

DVC, Kubernetes — Notions

Prochaine étape : Kubernetes en priorité

Cloud : Azure (Container Apps, PostgreSQL, Static Web Apps) — Opérationnel

SortirIA · *Fashion-Insta : architecture conçue*

Conduite de projet

Cadrage et étude de faisabilité — Opérationnel

Fashion-Insta Triage médical

Planning et budget, ROI — Opérationnel

Fashion-Insta SortirIA

Critères de succès, grille go / no-go — Opérationnel

Triage médical SortirIA

RGPD et cadre réglementaire (AI Act) — Opérationnel

Fashion-Insta Triage médical

Langues

Français — Langue maternelle

Anglais — Intermédiaire · B1

CLES 1 (équivalent B1), certification universitaire, 2012

Espagnol — Intermédiaire

Ce que demande le marché, et ce que je vais acquérir

En octobre 2026, j'ai relu quatre offres d'AI Engineer en France (Alten, Verra, SBS, Cyclife Digital Solutions du groupe EDF) et un panorama du métier. Le tableau compte combien d'offres citent chaque compétence, et la met en face de mon niveau. Trois offres sur quatre visent un profil confirmé. Je les prends comme une direction à suivre.

COMPÉTENCE DEMANDÉE	OFFRES	MON NIVEAU, MA PREUVE
Python, mise en production (FastAPI)	4 / 4	Autonome ; API dans 7 projets
LLM et LangChain ou LangGraph	4 / 4	Opérationnel ; SortirIA, Chess Agent, RAG OpenAgenda
MLOps : CI/CD, MLflow, monitoring	4 / 4	Opérationnel ; évaluation bloquante en CI, MLflow, Grafana
RAG, embeddings, bases vectorielles	3 / 4	Opérationnel ; pgvector, FAISS, Milvus
Agents et outils	3 / 4	Opérationnel ; agent LangGraph en production
Évaluation des LLM, hallucinations	3 / 4	Opérationnel ; juge calibré sur l'humain, citations vérifiées
PyTorch, Hugging Face	3 / 4	Opérationnel ; fine-tuning SFT et DPO
Recherche hybride (mots et vecteurs)	2 / 4	Opérationnel ; fusion des rangs dans SortirIA
Docker	2 / 4	Opérationnel ; 7 projets
Cloud (Azure, AWS, GCP)	2 / 4	Opérationnel ; SortirIA en production sur Azure
Kubernetes	2 / 4	Notions : ma priorité, pour passer de Container Apps à un déploiement orchestré
TensorFlow	2 / 4	Notions : j'ai choisi PyTorch, j'apprends TensorFlow pour reprendre des projets existants
Sécurité : OIDC, RBAC, secrets	2 / 4	Opérationnel ; API sécurisée, OIDC vers Azure, compte en lecture seule

Mes priorités, dans l'ordre :

1. **Kubernetes** : passer de Docker Compose et Container Apps à un déploiement orchestré.

2. **Un cloud IA managé** (Azure ML ou AWS SageMaker) et l'infrastructure en code (Terraform).

3. **Versionnage des données** (DVC) et TensorFlow, pour lire et reprendre des projets existants.

4. **Évaluation des LLM en production** : SortirIA suit déjà les coûts, les versions de consigne, les avis et la dérive. Il me reste à mesurer la qualité dans la durée, sur un vrai trafic.

Sources : offres Alten, Verra, SBS, Cyclife Digital Solutions (EDF) ; panorama JobRise, mai 2026.

Le référentiel du titre, compétence par compétence

Ma formation prépare au titre RNCP39775, « Expert en ingénierie et science des données » (niveau 7, OpenClassrooms). Il se valide avec trois blocs communs et une option. La mienne est l'option data science (bloc 5). Pour chacune de ces compétences, voici le projet qui la prouve et ce qu'on y trouve.

Bloc 1 · Manager et piloter un projet data et le développement d'une solution

`RNCP39775BC01`

COMPÉTENCE DU RÉFÉRENTIEL	OÙ JE LA PROUVE	CE QUI LE MONTRE
Recueillir les besoins métiers et leurs contraintes	rapport SortirIA · Fashion-Insta	Utilisateurs et contraintes de SortirIA, relecture du mentor, tests d'usage ; besoin client de Fashion-Insta
Définir, planifier et suivre le projet avec des indicateurs	rapport SortirIA · Fashion-Insta	Seuils fixés avant de mesurer, MVP en trois colonnes, feuille de route jusqu'au gel ; planning de 3 semaines

COMPÉTENCE DU RÉFÉRENTIEL	OÙ JE LA PROUVE	CE QUI LE MONTRE
Assurer la veille technique, juridique et réglementaire	SortirIA · Triage médical · Fashion-Insta	Licences des sources, collecte seulement sur autorisation écrite, RGPD ; anonymisation (Presidio) ; AI Act
Animer les échanges avec les parties prenantes, y compris en situation de handicap	rapport SortirIA · interface SortirIA	Mentor, testeurs, demandes aux villes ; interface utilisable au clavier et balisée pour les lecteurs d'écran (audit formel à venir)
Suivre le projet (délais, coûts, livrables, performance) et en rendre compte	rapport SortirIA · suivi des incidents	Jalons, budget Azure avec alertes, mail chaque nuit, 31 incidents tracés
Conseiller sur le plan stratégique et méthodologique	rapport SortirIA · Triage médical	Recommandation chiffrée après l'usage réel (la couverture d'abord) ; grille go / no-go
Auditer la solution data : historique, qualité, disponibilité	rapport SortirIA · SortirIA	Audit des sources (droit d'usage, volume, qualité, manques), script d'audit OpenAgenda
Évaluer les risques : accessibilité, sécurité, développement durable	limites SortirIA · SortirIA	Tableau des risques et parades ; secrets hors du code, limite de débit ; services qui s'éteignent d'eux-mêmes au repos
Identifier une solution technique adaptée	rapport SortirIA	Chaque choix mesuré contre son alternative : pgvector contre FAISS, règles contre LLM
Réaliser un prototype si nécessaire	SortirIA · Triage médical · Fashion-Insta	MVP en ligne en trois jours ; preuve de concept en quatre semaines ; PoC cadré
Présenter la solution et justifier ses choix	rapport SortirIA · Fashion-Insta	Dossier et rapport de conduite de projet ; présentation client de 52 diapositives

Bloc 2 · Concevoir et déployer une infrastructure complète de gestion des données RNCP39775BC02

COMPÉTENCE DU RÉFÉRENTIEL	OÙ JE LA PROUVE	CE QUI LE MONTRE
Configurer l'environnement de travail (machines physiques ou virtuelles)	SortirIA · Triage médical	Docker Compose en local, Azure Container Apps ; GPU de 6 Go puis cloud (RunPod)
Définir les processus de collecte, de traitement et de stockage	CheckIt.AI · SortirIA	Moteur multi-sources de CheckIt.AI (21 sources), réutilisé par SortirIA pour collecter, valider et stocker chaque nuit
Mettre en place une authentification conforme aux règles de sécurité	TechNova · SortirIA	API sécurisée ; connexion à Azure par jeton OIDC, compte de base en lecture seule, secrets hors du code
Structurer l'architecture des données et concevoir les bases (SQL ou NoSQL)	SortirIA · Chess Agent	13 tables et 6 vues PostgreSQL ; MongoDB et Milvus
Installer et paramétrer un SGBD et un outil d'extraction	SortirIA · CheckIt.AI	PostgreSQL et pgvector en local et sur Azure ; Airflow
Établir et exécuter des tests : SGBD, qualité des données, performance des requêtes	SortirIA	Tests du schéma sur un vrai PostgreSQL en CI, contrôle qualité de chaque nuit, temps de réponse P95
Modéliser une infrastructure compatible avec le système d'information existant	SortirIA · Fashion-Insta	Architecture Azure de SortirIA ; architecture cible conçue pour le client
Installer et tester l'infrastructure : opérationnalité, disponibilité, interopérabilité	SortirIA · procédures	Déploiement Azure, contrôle du site et de l'API toutes les 3 h, vérification après chaque déploiement

Bloc 3 · Créer et/ou adapter un modèle d'apprentissage RNCP39775BC03

COMPÉTENCE DU RÉFÉRENTIEL	OÙ JE LA PROUVE	CE QUI LE MONTRE
Configurer l'environnement d'analyse	Triage médical · Scoring crédit	Environnements reproductibles (uv, Docker), entraînement sur 6 Go de GPU
Nettoyer les données, de façon automatisée ou non	Scoring crédit · CheckIt.AI · Triage médical	Préparation automatisée ; validation et dédoublonnage ; audit et anonymisation
Identifier ou créer un modèle d'apprentissage adapté	Scoring crédit · CurelyticsIA · LunarLander · Triage médical	XGBoost, ResNet semi-supervisé, DQN et PPO, Qwen3 spécialisé
Préparer et transformer les données	Scoring crédit · CurelyticsIA · Triage médical	Variables, pseudo-étiquettes, jeux SFT et DPO
Entraîner le modèle	Scoring crédit · CurelyticsIA · LunarLander · Triage médical	Entraînements suivis (MLflow, W&B), échec diagnostiqué puis corrigé
Créer et lancer les tests avant mise en production	Triage médical · Chess Agent · SortirIA	Jeu de test gelé de 500 cas ; 1 029 tests ; évaluation qui bloque le déploiement
Évaluer le modèle selon des métriques définies	CurelyticsIA · Triage médical · RAG OpenAgenda · SortirIA	Rappel et F2 ; F1 et sous-triage ; RAGAS ; juge calibré sur l'humain
Identifier, configurer ou créer une API d'accès aux résultats	TechNova · Scoring crédit · Triage médical	API FastAPI journalisées
Exposer les résultats aux métiers : API, tableaux de bord	Scoring crédit · Triage médical · SortirIA	Streamlit, Grafana, interface web de SortirIA

Bloc 5 · Mon option, data science : optimiser des modèles d'apprentissage

RNCP39775BC05

COMPÉTENCE DU RÉFÉRENTIEL	OÙ JE LA PROUVE	CE QUI LE MONTRE
Suivre le cycle de vie du modèle et détecter les dérives	Scoring crédit · SortirIA	Evidently ; PSI chaque nuit et Evidently chaque mois ; versions dans les registres MLflow
Évaluer les performances de l'infrastructure	Scoring crédit · Triage médical · SortirIA	Latence P95 de 9,2 ms, 1,13 s et 6,4 s ; coût par question
Ajuster les paramètres d'entraînement, de test et de validation	LunarLander · Scoring crédit · Triage médical	Optuna ; QLoRA, SFT puis DPO
Automatiser le déploiement : intégration et livraison continues	TechNova · Scoring crédit · Triage médical · SortirIA	GitHub Actions, déploiement à chaque push

Source : fiche RNCP39775, France Compétences (intitulés des compétences résumés).

CHRONOLOGIE

Mon parcours

1998 – 2006 · DÉVELOPPEMENT

Développeur, puis cadre

Conception d'applications de gestion en SQL, Visual Basic et WinDev chez Alternative Informatique, à Montpellier, puis chef de projet informatique chez Spiral Informatique en 2001. Ensuite une période d'activité indépendante à Tenerife, où j'ai continué à travailler pour Alternative Informatique, tout en travaillant pour des boutiques et des entreprises françaises installées sur place. De retour à Montpellier, analyste-programmeur chez Store System Services, puis chez Helios.

2006 – 2009, PUIS 2011 – 2012 · PÉDAGOGIE

Éducation et transmission

J'ai passé le concours et suivi la formation d'éducateur technique spécialisé. En 2011-2012, j'ai préparé et obtenu une licence en sciences de l'éducation, à distance, en parallèle de mon travail de conseiller de vente. Cette licence m'a prouvé que je pouvais apprendre seul, chez moi : c'est ce qui m'a conforté plus tard dans mon choix d'OpenClassrooms. Pédagogie, accompagnement : je me sers encore de ces compétences pour conduire, expliquer et documenter mes projets.

2009 – 2025 · CONSEIL

Conseiller de vente en informatique

Mon dernier emploi : 16 ans à analyser, communiquer et comprendre les besoins d'un client. J'y ai aussi géré, à mon échelle, un rayon, adapté et suivi les procédures de l'entreprise, rencontré des fournisseurs, et développé d'autres compétences liées au conseil, à la vente et à la gestion.

FORMATION INGÉNIEUR IA · OPENCLASSROOMS

Du modèle au système

D'octobre 2025 à novembre 2026. C'est ma reconversion, ma possibilité de revenir à l'univers de l'informatique qui me tient tant à cœur : Computer Vision, Machine Learning et déploiement, RAG, MLOps, cadrage de projet, apprentissage semi-supervisé, renforcement, ingénierie des données, agents, fine-tuning de LLM. Puis SortirIA, mon projet personnel, que j'ai mis en production sur Azure.

AUJOURD'HUI

AI Engineer

Construire des outils IA que des gens utilisent vraiment, et pouvoir dire, chiffres à l'appui, quand ils marchent et où ils peuvent progresser.

BILAN

Prendre du recul

Ce que j’ai appris

Les leçons qui m'ont le plus marqué sont venues de mes erreurs.

- Un bon score peut cacher un mauvais modèle. Sur le triage, mon premier modèle prédisait 94,5 % des mots justes, mais ne trouvait la bonne priorité qu'une fois sur deux (51,8 %, pour trois priorités). Le sous-triage et le F1 m'en disent bien plus.
- Persévérer. La Base du triage peinait à finir ses réponses, et j'ai repris les données maintes et maintes fois. Quand elle a enfin terminé, j'ai surtout été soulagé.
- L'usage réel corrige les jeux de test. Sur mes questions, 97,8 % de pertinence. Sur celles des testeurs, 47 % de réponses exactes : ils cherchaient aussi des lieux.

Ce que je ferais différemment

Avec le recul, voici ce que je corrigerais dès le départ.

- Garder le jeu de test intact jusqu'au bout. Sur le triage, j'ai compris que je m'en étais servi pour prendre mes décisions, et que c'est cette façon de faire qui m'avait mené à ce résultat. Si je devais recommencer, je ferais tout différemment. C'est ce que j'ai appliqué ensuite : sur SortirIA, mes seuils étaient fixés avant de mesurer.
- Choisir le modèle sur la métrique qui compte vraiment, et l'évaluer sur assez de cas. Sur CurelyticsIA, je visais le rappel mais je sélectionnais sur la perte. Pour le RAG, 9 questions, c'était trop peu. Sur SortirIA, j'ai corrigé le tir : 10 jeux d'évaluation, rejoués à chaque push.
- Faire tester par de vrais utilisateurs plus tôt. Sur SortirIA, ils ont révélé en quelques jours un besoin que mes jeux de test laissaient dans l'ombre. Pour mes prochains projets, je ferai tester dès le premier prototype.

Les progrès que je constate

Quand je compare mes premiers projets et SortirIA…

- Mon premier livrable était un notebook. Aujourd'hui, c'est un site en ligne, ouvert à tous et testé par d'autres que moi.
- Face à un entraînement qui échoue, je cherche la cause avant de corriger, au lieu de relancer au hasard.
- Je réutilise mon propre code : SortirIA assemble et adapte des briques de cinq projets précédents.

Les défis qui restent

- Tenir une charge réelle, au-delà d'un service à faible trafic. Prochaine étape : un test de charge sur SortirIA, pour voir où il plie.
- Orchestrer avec Kubernetes. C'est ma priorité d'apprentissage, pour passer de Container Apps à un déploiement orchestré.
- Mesurer la qualité des réponses d'un LLM dans la durée, avec de vrais utilisateurs. SortirIA en pose déjà les bases : avis des visiteurs, juge calibré et dérive suivie chaque nuit.
- Travailler en équipe sur un produit IA déjà en production. C'est exactement ce que je cherche aujourd'hui.

ÉVOLUTION DE MA VISION DU MÉTIER

Au début de la formation

Entraîner un bon modèle

↓

Aujourd'hui

Construire un système IA fiable

Je voyais l'AI Engineer comme quelqu'un qui choisit et entraîne des modèles. Aujourd'hui, je le vois partir d'un besoin métier et fixer des critères de réussite. Il construit toute la chaîne : données, modèle, évaluation, service, monitoring. Et il aide à décider du bon moment pour déployer.
La formation m'a surtout appris à mener un projet IA comme en entreprise. Cadrer le besoin, chiffrer, mesurer, documenter. Et dire honnêtement où sont les limites.

```
Données → expérimentation → modèle → évaluation → déploiement → monitoring → amélioration continue
```

Ce dont je suis le plus fier, c'est le parcours : des difficultés de plus en plus fortes, et aujourd'hui de nombreux outils en main.

J'aime ce que je fais, ça me motive et ça me plaît. J'y passe du temps avec plaisir : je m'amuse.

SAVOIR-ÊTRE

Soft skills

Esprit d'analyse

Sur le triage médical, mon premier entraînement (Qwen3-Base) a échoué. Je l'ai diagnostiqué, mesuré, puis corrigé.

Curiosité et apprentissage continu

Onze projets dans des domaines très différents : scoring crédit, renforcement, LLM, cloud.

Communication et vulgarisation

Une documentation publiée pour mes principaux projets. Pour le triage, un rapport technique d'une vingtaine de pages qui commence par une synthèse pour les décideurs.

Gestion de projet et autonomie

Le PoC de triage livré en 4 semaines, avec une grille go / no-go. SortirIA en ligne en trois jours, avec une feuille de route jusqu'au gel du code.

Relation client

Seize ans à traduire un besoin client en solution concrète. Pour SortirIA, j'ai demandé l'autorisation aux sites des lieux avant toute collecte (les agendas ouverts sont sous licence ouverte), et je suis allé démarcher Sète et Frontignan pour trouver des lieux partenaires. J'attends encore leur réponse.

Créativité

Faire écrire à SortirIA ses propres corrections : chaque lundi, un agent lit les recherches ratées et me propose une pull request. Il me reste à relire et valider.

TÉMOIGNAGE

Le regard de mon mentor

> « Stéphane ne s'est pas contenté de développer une solution : il a également cherché à mesurer ses résultats, à justifier ses décisions et à définir des pistes d'amélioration réalistes. [...] C'était particulièrement enrichissant de travailler avec quelqu'un d'aussi motivé, impliqué et toujours prêt à approfondir ses connaissances. »
>
> — Mon mentor OpenClassrooms

CONTACT

Et si nous parlions de nos projets ?

Un projet IA, une opportunité, ou simplement l'envie d'échanger ? Écrivez-moi

gonzalezcourrier34@gmail.com

© 2026 Stéphane Gonzalez