PORTFOLIO • AI ENGINEER

Stéphane Gonzalez
AI Engineer

Je conçois des solutions d'intelligence artificielle de la donnée jusqu'au service en production : fine-tuning de LLM, RAG, agents, API, CI/CD, cloud et monitoring.

Machine Learning | Deep Learning | LLM & fine-tuning | RAG & agents | MLOps | Cloud Azure

---

11
Projets IA menés

6
Projets avec CI/CD

Azure
SortirIA en production

90,6 %
Triage médical : cas bien classés

PROFIL

À propos

De l'informatique et de la relation client à la conception de systèmes d'intelligence artificielle.

Développeur de formation (SQL, Visual Basic, WinDev), puis seize ans de conseil client en informatique, j'ai choisi de revenir à la technique en me spécialisant dans l'intelligence artificielle avec la formation Ingénieur IA d'OpenClassrooms.

Mes projets m'ont conduit du Machine Learning classique au déploiement d'API, puis au RAG, aux agents et au fine-tuning de LLM, toujours avec la même exigence : un système testé, reproductible et mesuré.

Objectif professionnel : rejoindre une équipe comme AI Engineer pour concevoir et mettre en production des solutions à base de LLM, avec une attention particulière à l'évaluation et au monitoring.

Ma carte mentale

Ce portfolio est construit à partir de cette carte : chaque branche correspond à une section de la page.

Stéphane Gonzalez, AI Engineer

1. Profil

- Développeur, puis 16 ans de conseil client en informatique
- Formation Ingénieur IA, OpenClassrooms
- Objectif : AI Engineer, évaluation et monitoring

2. Projets

- SortirIA, projet personnel en ligne, avec son rapport
- Triage médical, Chess Agent, CheckIt.AI
- RAG OpenAgenda, scoring crédit et 5 autres
- 10 projets validés par OpenClassrooms

3. Compétences

- ML et données
- Deep Learning et LLM
- Développement et déploiement
- MLOps et cloud
- Conduite de projet

4. Réflexion

- Ce que j'ai appris
- Ce que je ferais différemment
- Progrès et défis restants
- Ma vision du métier
- Compétences en cours d'acquisition

5. Soft skills

- Esprit d'analyse
- Curiosité
- Communication
- Gestion de projet
- Relation client
- Créativité

Carte complète, avec chaque compétence reliée à ses preuves : format Freeplane / Xmind (.mm) · version texte

RÉALISATIONS

Projets

Onze projets menés pendant ma formation, du plus récent au plus ancien ; les dix projets de formation sont validés par OpenClassrooms. Chacun est livré avec son code ou ses livrables, et chaque carte y renvoie. Tous sont des projets individuels : chaque carte précise mon rôle et la principale difficulté rencontrée. Le dernier, SortirIA, est mon projet personnel : il réunit les briques des précédents dans un service en ligne.

Projet personnel • RAG • Agent • Production sur Azure Oct.-nov. 2026 · en ligne

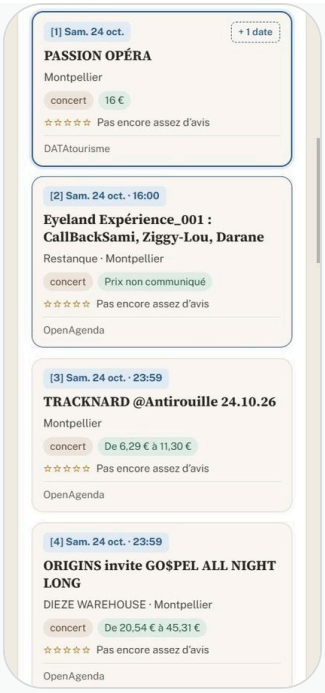
SortirIA

Un assistant de sorties pour Montpellier et le bassin de Thau : on écrit sa demande comme on la dirait (« un concert gratuit ce week-end à Sète »), SortirIA répond avec des sorties qui respectent la date, le lieu, le public et le budget. Chaque nuit, un agent LangGraph collecte et vérifie les agendas ouverts (OpenAgenda, DATAtourisme, programmes en PDF) ; la recherche combine filtres SQL, mots et vecteurs (pgvector) et Mistral rédige la réponse. Le service est en ligne sur Azure, déployé à chaque push et surveillé.

Mon rôle	Seul, de bout en bout : cadrage, demandes d'autorisation aux sources, code, déploiement sur Azure et suivi en production.
Le défi	Respecter à coup sûr la date, le lieu, le public et le budget d'une demande écrite librement, avec des agendas hétérogènes à collecter et vérifier chaque nuit.



L'accueil : on écrit sa demande comme on la dirait.



La réponse : des cartes datées, avec prix et source citée.

98,7 %
Contraintes respectées

97,8 %
Pertinence des 3 premières sorties

98,6 %
Accord du juge LLM avec l'humain

6,4 s
Temps de réponse P95

0,12 $
Coût Mistral pour 1 000 questions

CONDUITE DE PROJET

1. Besoin

Trouver une sortie qui convient vraiment (date, lieu, public, budget), sans parcourir dix agendas.

2. Audit des données

Sources ouvertes et autorisées seulement ; chaque fiche vérifiée, dédoublonnée, attribuée à sa source.

3. Solution

Agent LangGraph la nuit, PostgreSQL + pgvector, FastAPI, Angular, Mistral ; code repris de mes projets précédents et adapté.

4. Aide à la décision

Seuils fixés avant de mesurer (95 % de contraintes, 70 % de pertinence) ; juge calibré sur l'humain ; usage réel mesuré (93 questions de testeurs, 47 % de réponses exactes) : la couverture devient la priorité.

5. Contrôle

Environ 10 $ par mois ; évaluation rejouée en CI (déploiement bloqué sous 95 %) ; Grafana, MLflow, dérive suivie chaque nuit (PSI) et chaque mois (Evidently), alertes et budget Azure.

THÈMES MLOPS DU PROJET FINAL

La consigne propose quatre thèmes. Voici ce que SortirIA en couvre, et comment, pour un service qui appelle Mistral au lieu d'entraîner son propre modèle.

Cycle de vie des modèles Couvert	CI à chaque push : tests sur un vrai PostgreSQL et évaluation de la recherche rejouée, déploiement bloqué sous 95 %. CD vers Azure, contrôle du service en ligne toutes les 3 h, MLflow sur le poste pour chaque évaluation et chaque collecte lancée en local.
Suivi de la dérive Couvert	Chaque nuit, les 7 derniers jours comparés aux 28 précédents (PSI) : ce que les visiteurs demandent (zone, public, type de sortie), ce que SortirIA répond (exacte, élargie, introuvable ; latence, avis) et ce que les sources apportent (volumes, rejets, juge de qualité). Rapport le lundi, alerte si la dérive est forte, suivi dans Grafana. Chaque mois, un rapport Evidently complet (mois contre mois) produit par GitHub Actions, la base n'étant ouverte que le temps du rapport. Pas de verdict sur trop peu de données.
Réentraînement automatique Adapté	Pas de modèle à réentraîner : SortirIA appelle Mistral. La boucle d'amélioration est l'agent du lundi : il lit les recherches ratées et les pouces bas, puis ouvre une pull request par correction (synonyme, agenda à lire). Elle est testée en CI, je la valide, puis elle est déployée. Un fine-tuning est prévu quand les avis réels suffiront.

Versionnage des données et des modèles Couvert	Les 8 consignes sont dans le Prompt Registry de MLflow ; la chaîne (modèles Mistral, versions des consignes, empreintes des 10 jeux d'évaluation) dans le Model Registry, avec les alias « production » et « précédente ». La CI refuse une consigne modifiée sans nouvelle version, et chaque réponse garde la sienne. Pas de DVC : les jeux, environ 1 Mo, restent dans Git.

LangGraph · Mistral · PostgreSQL / pgvector · FastAPI · Angular · Azure Container Apps · GitHub Actions · Grafana · MLflow · Evidently · Airflow

Site en ligne → **Code →** **Rapport de conduite de projet →** **Rapport en PDF →**
Dossier du projet → **Documentation →**

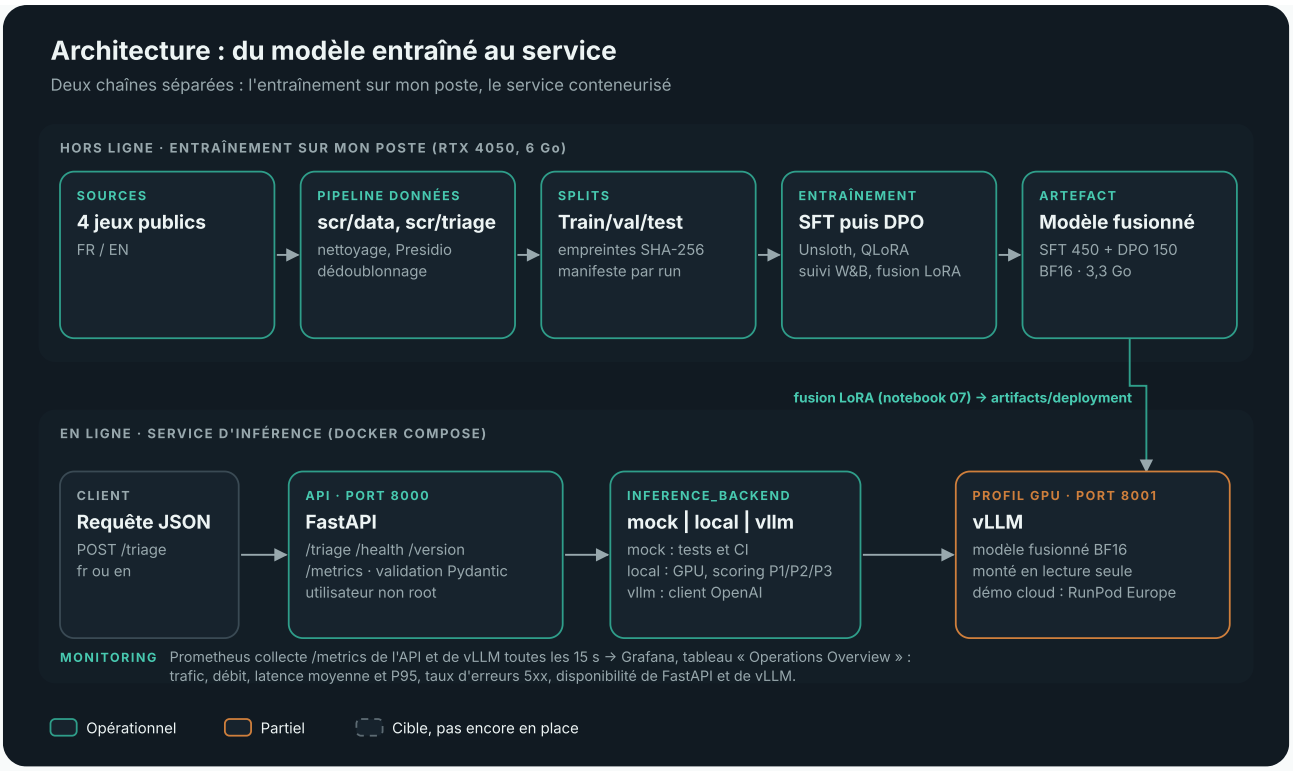
LLM • Fine-tuning • Production

Sept.-oct. 2026 · ✓ **Validé**

Agent IA de triage médical

Un petit modèle de langage (Qwen3-1.7B) spécialisé pour classer un patient des urgences en P1, P2 ou P3 et justifier sa décision, en français et en anglais. Entraîné par SFT puis DPO avec QLoRA sur une carte graphique de 6 Go, servi par vLLM derrière une API FastAPI journalisée et surveillée.

Mon rôle	Seul : audit et anonymisation des données, entraînement, service du modèle, tests et documentation.
Le défi	Spécialiser un modèle sur une carte de 6 Go sans sous-trier les urgences : le premier entraînement (Qwen3-Base) a échoué, je l'ai diagnostiqué puis corrigé.



Chaque brique est marquée opérationnelle ou partielle : l'état réel, pas l'état visé.

453 / 500
Cas du test gelé bien classés

90,6 %
F1 macro

93,4 %
Urgences P1 reconnues

5,4 %
Sous-triage

1,13 s
Latence P95

CONDUITE DE PROJET

1. Besoin

Aider les infirmiers d'accueil à trier les patients, avec une explication.

2. Audit des données

164 477 lignes publiques auditées, anonymisées (Presidio), réduites à 5 000 cas équilibrés.

3. Solution

QLoRA, SFT puis DPO, modèle fusionné et servi par vLLM.

4. Aide à la décision

Grille go / no-go et pilote en quatre phases, le modèle en second avis.

5. Contrôle

4 semaines, 6 Go de GPU, CI avec 40 tests, test gelé rejoué sur le modèle servi.

Qwen3 · PyTorch · QLoRA · SFT / DPO · vLLM · FastAPI

Prometheus / Grafana | W&B | GitHub Actions

Code → **Documentation →** **Rapport technique →**

Agent IA • RAG Août 2026 · ✓ **Validé**

Chess Agent

Aide à l'apprentissage des ouvertures d'échecs. Un agent LangGraph combine Stockfish, Lichess, un RAG sur Wikichess et un LLM local pour expliquer une position en français.

Mon rôle	Seul : architecture de l'agent, backend FastAPI, interface Angular, tests et CI.
Le défi	Ne pas laisser le LLM inventer un coup ou une évaluation : Stockfish calcule, les sources apportent le contexte, le LLM explique seulement.

1 029	≥ 86 %
Tests automatisés	Couverture exigée par la CI

LangGraph | Milvus | Ollama | FastAPI | MongoDB | Angular

Code → **Documentation →**

Data engineering

Juillet 2026 · ✓ Validé

CheckIt.AI

Moteur de collecte multi-sources réutilisable : un moteur par type de source, un adaptateur et une configuration YAML par fournisseur. Validation, déduplication et contrôle qualité, orchestrés par Airflow. Premier cas d'usage : le fact-checking. SortirIA le réutilise.

Mon rôle	Seul : architecture du moteur, connecteurs, orchestration Airflow et tableau de bord.
Le défi	Faire entrer des sources très différentes dans un même format fiable (dates, liens, doublons, images vérifiés) sans dupliquer le code.

21

Sources branchées (RSS, API, web, réseaux sociaux, datasets)

Airflow · PostgreSQL · YAML · Docker · Streamlit

Code → **Documentation →**

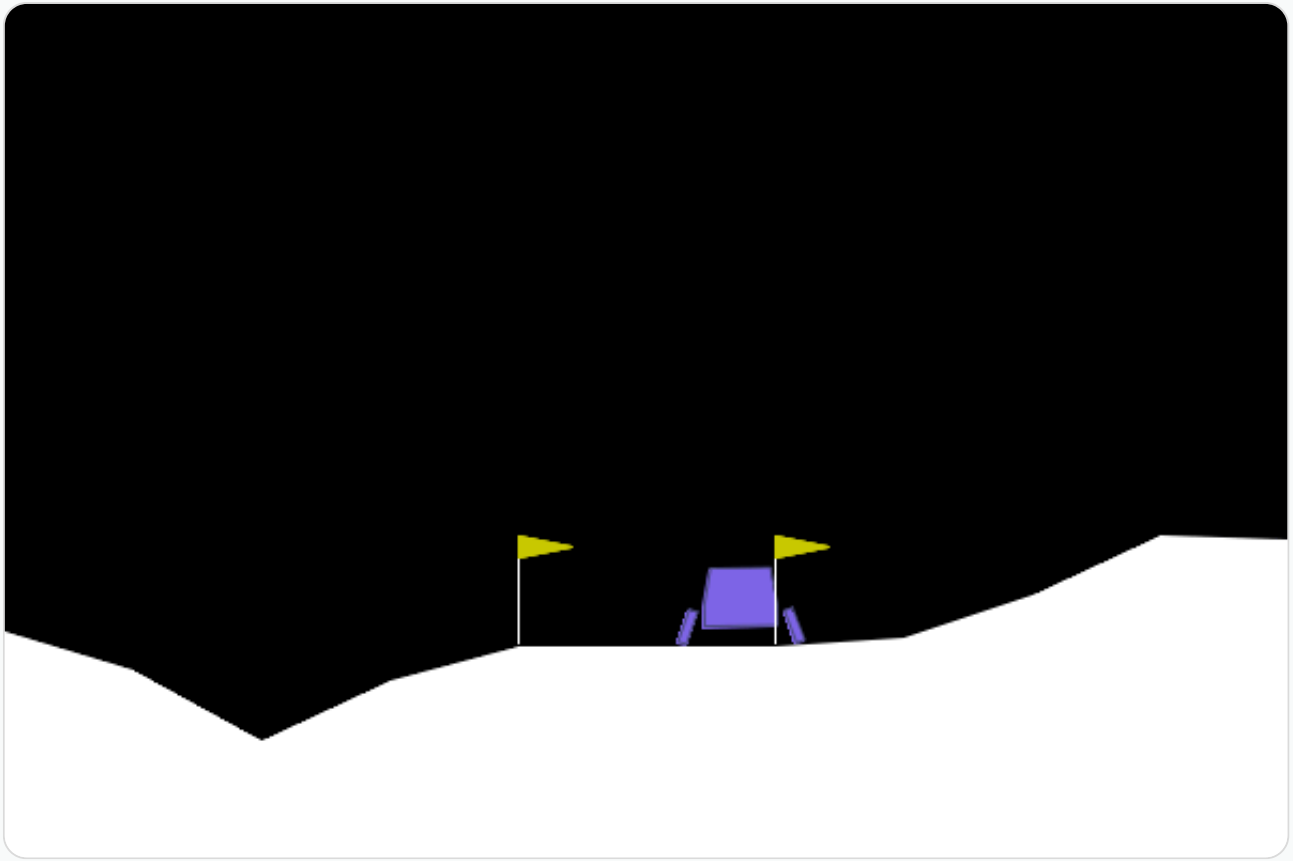
Reinforcement Learning

Juillet 2026 · ✓ Validé

Atterrissage LunarLander

Entraînement d'agents DQN et PPO pour poser un module lunaire, optimisation des hyperparamètres et restitution dans une API et un tableau de bord.

Mon rôle	Seul : entraînement des agents, réglage des hyperparamètres, API et tableau de bord.
Le défi	Obtenir un atterrissage stable et reproductible : comparer DQN et PPO, puis régler leurs hyperparamètres avec Optuna.



Un atterrissage réussi par l'agent entraîné · voir l'animation (9 s)

Stable-Baselines3 · Gymnasium · Optuna · FastAPI

Code →

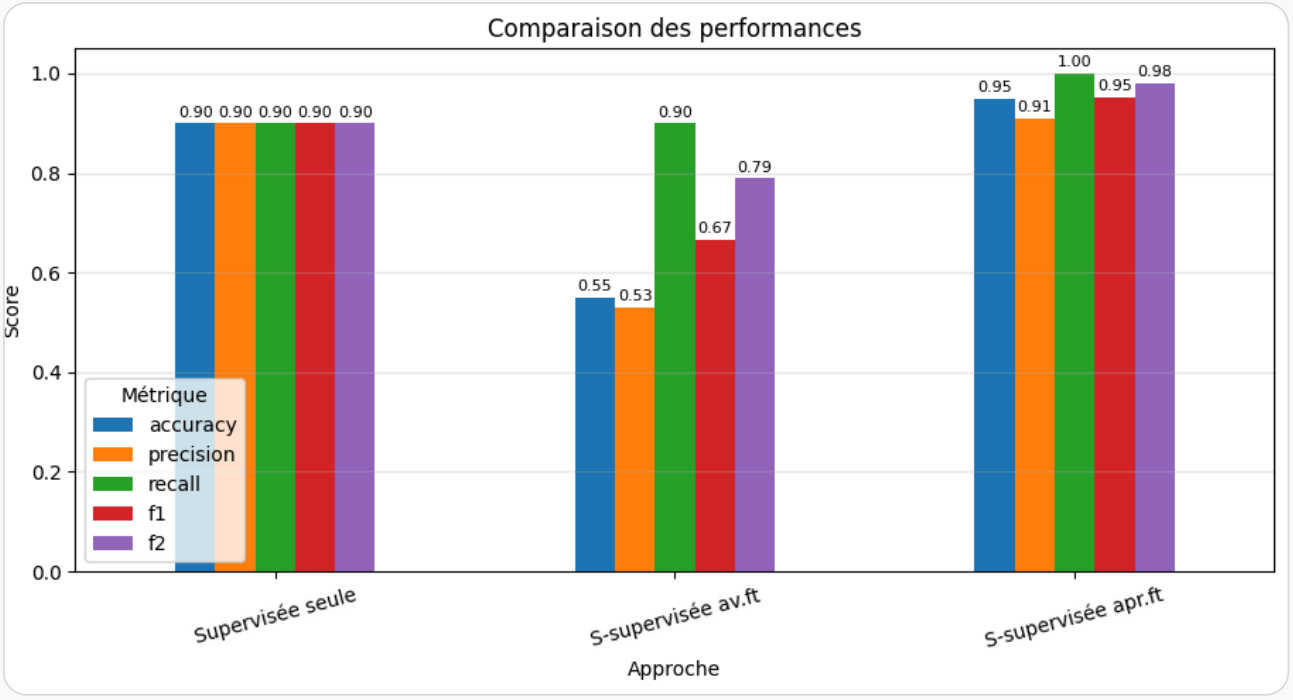
Vision • Semi-supervisé

Juin 2026 · ✓ Validé

CurelyticsIA · BrainScanAI

Détection de tumeurs sur des IRM cérébrales avec peu d'images annotées : caractéristiques extraites par ResNet50, ACP et clustering, pseudo-étiquettes, puis entraînement d'un ResNet18. Étude de coût pour un budget de 5 000 €.

Mon rôle	Seul : pipeline semi-supervisé, évaluation et étude de coût.
Le défi	Apprendre avec très peu d'images annotées sans manquer de tumeur : le rappel prime sur tout le reste.



Supervisé seul, puis semi-supervisé avant et après fine-tuning.

1,00
Rappel (tumeurs détectées)

0,98
F2-score

0,95
Accuracy, contre 0,90 en supervisé seul

PyTorch · ResNet · Clustering · Pseudo-labels

Code →

Cadrage • Gestion de projet

Mai 2026 · ✓ Validé

Cadrage du POC Fashion-Insta

Cadrage d'un système de recommandation de vêtements par la vision pour une enseigne de mode : besoin métier, choix de l'approche (CLIP + recherche vectorielle), planning de 3 semaines, budget de 13 à 15 k€, KPI de succès, architecture cible sur Azure, ROI et RGPD.

Mon rôle	Seul, dans le rôle du chef de projet IA : cadrage, chiffrage et présentation au client.
Le défi	Permettre une décision avant d'écrire du code : KPI, budget, planning et contraintes RGPD fixés pour un go / no-go.

Cadrage · Budget & ROI · Architecture Azure · RGPD · CLIP

Livrable : présentation de 52 diapositives

ML • MLOps

Avril-mai 2026 · ✓ Validé

Scoring crédit Prêt à dépenser

Modèle de scoring mis en production : API, suivi des expériences MLflow, monitoring de la dérive avec Evidently, optimisation de l'inférence avec ONNX.

Mon rôle	Seul : API, suivi MLflow, monitoring de la dérive, optimisation et CI.
Le défi	Garder un modèle fiable après son déploiement : tracer chaque appel, détecter la dérive et accélérer l'inférence.

11,8 ms	15,7 ms	−18,6 %
Latence API moyenne	Latence API P95	Temps de traitement après optimisation

LightGBM · MLflow · Evidently · ONNX · GitHub Actions

Code →

LLM • RAG

Mars-avril 2026 · ✓ Validé

Assistant RAG OpenAgenda

Recommandation d'événements culturels : préfiltrage structuré (ville, date, type), recherche sémantique FAISS, classement explicable et réponse générée par Mistral. Évaluation RAGAS sur des questions claires, ambiguës et hors corpus.

Mon rôle	Seul : collecte OpenAgenda, pipeline RAG, évaluation et conteneurisation.
Le défi	Comprendre une demande libre, parfois floue, et ne répondre qu'avec les événements retrouvés, sans en inventer.

LangChain · FAISS · Mistral · RAGAS · Docker

Code →

ML • Déploiement

Février 2026 · ✓ Validé

TechNova Partners

Prédiction du départ des employés, déployée en API FastAPI sécurisée avec base PostgreSQL et traçabilité des prédictions. L'API est en ligne.

Mon rôle	Seul : base de données, API sécurisée, tests, CI/CD et mise en ligne.
Le défi	Rendre le modèle utilisable en production : aucune préparation des données dans l'API, chaque prédiction tracée en base.

scikit-learn · FastAPI · PostgreSQL · Hugging Face Spaces

Code → **API en ligne →**

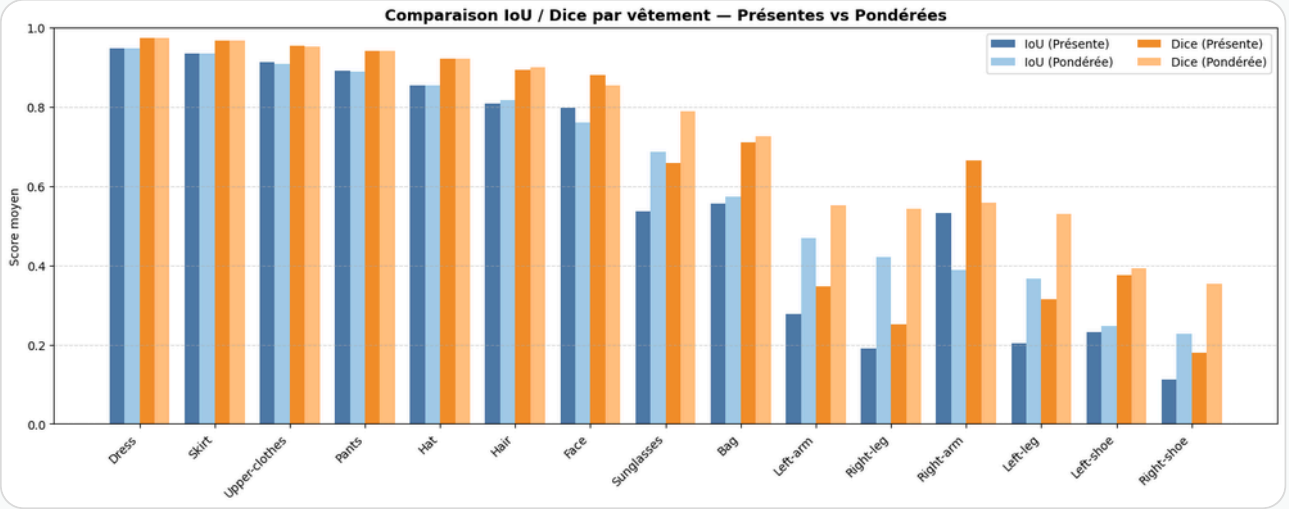
Vision • Segmentation

Oct.-nov. 2025 · ✓ Validé

ModeTrends

Segmentation de vêtements dans des photos d'influenceurs via un modèle Hugging Face appelé par API, puis analyse des tendances par catégorie de vêtement.

Mon rôle	Seul : appels au modèle, mesure de sa qualité et analyse des tendances.
Le défi	Juger un modèle que je n'ai pas entraîné : l'IoU et le Dice par vêtement montrent que les petits éléments (chaussures, bras) sont mal segmentés.



Qualité de la segmentation, vêtement par vêtement.

Hugging Face API · pandas · Matplotlib

Code →

AUTO-ÉVALUATION

Compétences

Chaque niveau est une auto-évaluation de mon autonomie, et chaque compétence renvoie aux projets où je l'ai mise en œuvre.

Notions · En progression · Opérationnel

Autonome

Machine Learning & données

Python — Autonome

Scoring crédit · Chess Agent · Triage médical · SortirIA

pandas / NumPy — Opérationnel

Scoring crédit · CurelyticsIA · CheckIt.AI

scikit-learn, LightGBM, XGBoost — Opérationnel

TechNova · Scoring crédit

SQL, PostgreSQL, pgvector — Opérationnel

TechNova · Scoring crédit · CheckIt.AI · SortirIA

Optuna, SHAP — Opérationnel

TechNova · Scoring crédit

Deep Learning & LLM

PyTorch — Opérationnel
CurelyticsIA · Triage médical

Hugging Face Transformers, PEFT — Opérationnel
Triage médical

Fine-tuning LoRA / QLoRA, SFT, DPO — Opérationnel
Triage médical

RAG : LangChain, FAISS, Milvus, pgvector, RAGAS — Opérationnel
RAG OpenAgenda · Chess Agent · SortirIA

Évaluation des LLM : juge LLM calibré sur l'humain, kappa, AC1 — Opérationnel
RAG OpenAgenda · SortirIA

Agents : LangGraph — Opérationnel
Chess Agent · SortirIA

Vision : CNN, OpenCV, segmentation — Opérationnel
CurelyticsIA · ModeTrends

Reinforcement Learning : Stable-Baselines3 — Opérationnel
LunarLander

Anonymisation : Presidio — En progression
Triage médical

TensorFlow — Notions
En cours d'acquisition

Développement & déploiement

FastAPI — Opérationnel

TechNova · Scoring crédit · RAG OpenAgenda · Chess Agent · Triage médical · SortirIA

Docker, Docker Compose — Opérationnel

TechNova · Scoring crédit · RAG OpenAgenda · CheckIt.AI · Chess Agent · Triage médical · SortirIA

Tests et qualité : pytest, ruff, pyright, mypy — Opérationnel

Scoring crédit · CheckIt.AI · Chess Agent · Triage médical · SortirIA

Streamlit — Opérationnel

TechNova · Scoring crédit · RAG OpenAgenda

vLLM — Opérationnel

Triage médical

Angular — Opérationnel

Chess Agent · SortirIA

MLOps & cloud

CI/CD : GitHub Actions — Opérationnel

TechNova · Scoring crédit · RAG OpenAgenda · Chess Agent · Triage médical · SortirIA

MLflow — Opérationnel

Scoring crédit · SortirIA

Weights & Biases — Opérationnel

Triage médical

Airflow — Opérationnel

CheckIt.AI · SortirIA

Monitoring et dérive : Evidently, PSI, Prometheus, Grafana — Opérationnel

Scoring crédit · Triage médical · SortirIA

ONNX Runtime — Opérationnel

Scoring crédit

GPU cloud (RunPod), Hugging Face Spaces — En progression

TechNova · Triage médical

Cloud IA managé : Azure ML, SageMaker, Vertex AI — Notions

En cours d'acquisition

DVC, Kubernetes — Notions

En cours d'acquisition

Cloud : Azure (Container Apps, PostgreSQL, Static Web Apps) — Opérationnel

SortirIA *Fashion-Insta : architecture conçue*

Conduite de projet

Cadrage et étude de faisabilité — Opérationnel

Fashion-Insta Triage médical

Planning et budget, ROI — Opérationnel

Fashion-Insta SortirIA

Critères de succès, grille go / no-go — Opérationnel

Triage médical SortirIA

RGPD et cadre réglementaire (AI Act) — Opérationnel

Fashion-Insta Triage médical

Langues

Français — Langue maternelle

Anglais — Intermédiaire

Espagnol — Intermédiaire

Ce que demande le marché, et ce que je vais acquérir

J'ai relu en octobre 2026 quatre offres d'AI Engineer en France (Alten, Verra, SBS, Cyclife Digital Solutions du groupe EDF) et un panorama du métier. Ce tableau compte combien des quatre offres citent chaque compétence, et la met en face de mon niveau. Trois offres sur quatre visent un profil confirmé : je les lis comme une direction, pas comme une barre d'entrée.

COMPÉTENCE DEMANDÉE	OFFRES	MON NIVEAU, MA PREUVE
Python, mise en production (FastAPI)	4 / 4	Autonome ; API dans 6 projets
LLM et LangChain ou LangGraph	4 / 4	Opérationnel ; SortirIA, Chess Agent, RAG OpenAgenda
MLOps : CI/CD, MLflow, monitoring	4 / 4	Opérationnel ; évaluation bloquante en CI, MLflow, Grafana
RAG, embeddings, bases vectorielles	3 / 4	Opérationnel ; pgvector, FAISS, Milvus
Agents et outils	3 / 4	Opérationnel ; agent LangGraph en production
Évaluation des LLM, hallucinations	3 / 4	Opérationnel ; juge calibré sur l'humain, citations vérifiées
PyTorch, Hugging Face	3 / 4	Opérationnel ; fine-tuning SFT et DPO
Recherche hybride (mots et vecteurs)	2 / 4	Opérationnel ; fusion des rangs dans SortirIA
Docker	2 / 4	Opérationnel ; 7 projets
Cloud (Azure, AWS, GCP)	2 / 4	Opérationnel ; SortirIA en production sur Azure
Kubernetes	2 / 4	Notions : en cours d'acquisition, en priorité
TensorFlow	2 / 4	Notions : en cours d'acquisition

COMPÉTENCE DEMANDÉE	OFFRES	MON NIVEAU, MA PREUVE
Sécurité : OIDC, RBAC, secrets	2 / 4	Notions : à approfondir

Mes priorités, dans l'ordre :

1. **Kubernetes** : passer de Docker Compose et Container Apps à un déploiement orchestré.

2. **Un cloud IA managé** (Azure ML ou AWS SageMaker) et l'infrastructure en code (Terraform).

3. **Sécurité des services IA** : OIDC, droits par rôle, gestion des secrets.

4. **Versionnage des données** (DVC) et TensorFlow, pour lire et reprendre des projets existants.

5. **Évaluation des LLM en production** : SortirIA suit déjà coûts, versions de consigne, avis et dérive ; reste la qualité mesurée dans la durée, sur un vrai trafic.

Sources : offres Alten, Verra, SBS, Cyclife Digital Solutions (EDF) ; panorama JobRise, mai 2026.

Le référentiel du titre, compétence par compétence

Ma formation prépare au titre RNCP39775, « Expert en ingénierie et science des données » (niveau 7, OpenClassrooms). Il se valide avec trois blocs communs et une option ; la mienne est l'option data science (bloc 5). Pour chacune de ces compétences, voici le projet qui la prouve et ce qu'on y trouve.

Bloc 1 · Manager et piloter un projet data et le développement d'une solution

RNCP39775BC01

COMPÉTENCE DU RÉFÉRENTIEL	OÙ JE LA PROUVE	CE QUI LE MONTRE
Recueillir les besoins métiers et leurs contraintes	rapport SortirIA · Fashion-Insta	Utilisateurs et contraintes de SortirIA, relecture du mentor, tests d'usage ; besoin client de Fashion-Insta
Définir, planifier et suivre le projet avec des indicateurs	rapport SortirIA · Fashion-Insta	Seuils fixés avant de mesurer, MVP en trois colonnes, feuille de route jusqu'au gel ; planning de 3 semaines
Assurer la veille technique, juridique et réglementaire	SortirIA · Triage médical · Fashion-Insta	Licences des sources, collecte seulement sur autorisation écrite, RGPD ; anonymisation (Presidio) ; AI Act
Animer les échanges avec les parties prenantes, y compris en situation de handicap	rapport SortirIA · interface SortirIA	Mentor, testeurs, demandes aux villes ; interface utilisable au clavier et balisée pour les lecteurs d'écran (sans audit formel)
Suivre le projet (délais, coûts, livrables, performance) et en rendre compte	rapport SortirIA · suivi des incidents	Jalons, budget Azure avec alertes, mail chaque nuit, plus de 25 incidents tracés
Conseiller sur le plan stratégique et méthodologique	rapport SortirIA · Triage médical	Recommandation chiffrée après l'usage réel (la couverture d'abord) ; grille go / no-go
Auditer la solution data : historique, qualité, disponibilité	rapport SortirIA · SortirIA	Audit des sources (droit d'usage, volume, qualité, manques), script d'audit OpenAgenda
Évaluer les risques : accessibilité, sécurité, développement durable	limites SortirIA · SortirIA	Tableau des risques et parades ; secrets hors du code, limite de débit ; services qui s'éteignent sans usage

COMPÉTENCE DU RÉFÉRENTIEL	OÙ JE LA PROUVE	CE QUI LE MONTRE
Identifier une solution technique adaptée	rapport SortirIA	Chaque choix mesuré contre son alternative : pgvector contre FAISS, règles contre LLM
Réaliser un prototype si nécessaire	SortirIA · Triage médical · Fashion-Insta	MVP en ligne en trois jours ; preuve de concept en quatre semaines ; POC cadré
Présenter la solution et justifier ses choix	rapport SortirIA · Fashion-Insta	Dossier et rapport de conduite de projet ; présentation client de 52 diapositives

Bloc 2 · Concevoir et déployer une infrastructure complète de gestion des données `RNCP39775BC02`

COMPÉTENCE DU RÉFÉRENTIEL	OÙ JE LA PROUVE	CE QUI LE MONTRE
Configurer l'environnement de travail (machines physiques ou virtuelles)	SortirIA · Triage médical	Docker Compose en local, Azure Container Apps ; GPU de 6 Go puis cloud (RunPod)
Définir les processus de collecte, de traitement et de stockage	CheckIt.AI · SortirIA	Moteur multi-sources (21 sources) ; collecte, validation et stockage chaque nuit
Mettre en place une authentification conforme aux règles de sécurité	TechNova · SortirIA	API sécurisée ; connexion à Azure sans mot de passe (OIDC), compte de base en lecture seule, secrets hors du code
Structurer l'architecture des données et concevoir les bases (SQL ou NoSQL)	SortirIA · Chess Agent	13 tables et 6 vues PostgreSQL ; MongoDB et Milvus
Installer et paramétrer un SGBD et un outil d'extraction	SortirIA · CheckIt.AI	PostgreSQL et pgvector en local et sur Azure ; Airflow

COMPÉTENCE DU RÉFÉRENTIEL	OÙ JE LA PROUVE	CE QUI LE MONTRE
Établir et exécuter des tests : SGBD, qualité des données, performance des requêtes	SortirIA	Tests du schéma sur un vrai PostgreSQL en CI, contrôle qualité de chaque nuit, temps de réponse P95
Modéliser une infrastructure compatible avec le système d'information existant	SortirIA · Fashion-Insta	Architecture Azure de SortirIA ; architecture cible conçue pour le client
Installer et tester l'infrastructure : opérationnalité, disponibilité, interopérabilité	SortirIA · procédures	Déploiement Azure, contrôle du site et de l'API toutes les 3 h, vérification après chaque déploiement

Bloc 3 · Créer et/ou adapter un modèle d'apprentissage `RNCP39775BC03`

COMPÉTENCE DU RÉFÉRENTIEL	OÙ JE LA PROUVE	CE QUI LE MONTRE
Configurer l'environnement d'analyse	Triage médical · Scoring crédit	Environnements reproductibles (uv, Docker), entraînement sur 6 Go de GPU
Nettoyer les données, de façon automatisée ou non	Scoring crédit · CheckIt.AI · Triage médical	Préparation automatisée ; validation et dédoublonnage ; audit et anonymisation
Identifier ou créer un modèle d'apprentissage adapté	Scoring crédit · CurelyticsIA · LunarLander · Triage médical	LightGBM, ResNet semi-supervisé, DQN et PPO, Qwen3 spécialisé
Préparer et transformer les données	Scoring crédit · CurelyticsIA · Triage médical	Variables, pseudo-étiquettes, jeux SFT et DPO

COMPÉTENCE DU RÉFÉRENTIEL	OÙ JE LA PROUVE	CE QUI LE MONTRE
Entraîner le modèle	Scoring crédit · CurelyticsIA · LunarLander · Triage médical	Entraînements suivis (MLflow, W&B), échec diagnostiqué puis corrigé
Créer et lancer les tests avant mise en production	Triage médical · Chess Agent · SortirIA	Jeu de test gelé de 500 cas ; 1 029 tests ; évaluation qui bloque le déploiement
Évaluer le modèle selon des métriques définies	CurelyticsIA · Triage médical · RAG OpenAgenda · SortirIA	Rappel et F2 ; F1 et sous-triage ; RAGAS ; juge calibré sur l'humain
Identifier, configurer ou créer une API d'accès aux résultats	TechNova · Scoring crédit · Triage médical	API FastAPI journalisées
Exposer les résultats aux métiers : API, tableaux de bord	Scoring crédit · Triage médical · SortirIA	Streamlit, Grafana, interface web de SortirIA

Bloc 5 · Mon option, data science : optimiser des modèles d'apprentissage

RNCP39775BC05

COMPÉTENCE DU RÉFÉRENTIEL	OÙ JE LA PROUVE	CE QUI LE MONTRE
Suivre le cycle de vie du modèle et détecter les dérives	Scoring crédit · SortirIA	Evidently ; PSI chaque nuit et Evidently chaque mois ; versions dans les registres MLflow
Évaluer les performances de l'infrastructure	Scoring crédit · Triage médical · SortirIA	Latence P95 de 15,7 ms, 1,13 s et 6,4 s ; coût par question
Ajuster les paramètres d'entraînement, de test et de validation	LunarLander · Scoring crédit · Triage médical	Optuna ; QLoRA, SFT puis DPO

COMPÉTENCE DU RÉFÉRENTIEL	OÙ JE LA PROUVE	CE QUI LE MONTRE
Automatiser le déploiement : intégration et livraison continues	TechNova · Scoring crédit · Triage médical · SortirIA	GitHub Actions, déploiement à chaque push

Source : fiche RNCP39775, France Compétences (intitulés des compétences résumés).

CHRONOLOGIE

Mon parcours

1998 – 2006 · DÉVELOPPEMENT

Développeur, puis cadre

Applications de gestion en SQL, Visual Basic et WinDev chez Alternative Informatique (Montpellier), cadre en 2001 ; une période d'activité indépendante à Tenerife.

2006 – 2011 · PÉDAGOGIE

Éducation et transmission

Formation d'éducateur technique spécialisé, puis licence en sciences de l'éducation (2011).

2009 – 2025 · CONSEIL

Conseiller de vente en informatique

Seize ans à comprendre le besoin d'un client et à lui expliquer une solution technique simplement.

FORMATION INGÉNIEUR IA · OPENCLASSROOMS

Du modèle au système

Octobre 2025 à novembre 2026 : vision, Machine Learning et déploiement, RAG, MLOps, cadrage de projet, apprentissage semi-supervisé, renforcement, ingénierie des données, agents, fine-tuning de LLM, puis SortirIA, mon projet personnel, mis en production sur Azure.

AUJOURD'HUI

AI Engineer

Concevoir des solutions IA complètes, évaluables, reproductibles et déployables.

BILAN

Prendre du recul

Ce que j'ai appris

- La qualité des données prime sur leur quantité.
- Une métrique seule ne suffit pas à juger un modèle : sur le triage, le sous-triage compte autant que le F1.
- L'analyse des erreurs complète l'évaluation chiffrée.
- La reproductibilité doit être pensée dès le début.
- Un juge LLM se calibre sur un humain : chaque version de SortirIA lui a retiré ce que le code vérifie mieux que lui.
- L'usage réel corrige les jeux de test : 97,8 % de pertinence sur mes questions, 47 % de réponses exactes sur celles des testeurs, qui cherchaient aussi des lieux.

Ce que je ferais différemment

- Figer plus tôt les jeux de données.
- Définir les critères de succès avant l'entraînement.
- Automatiser davantage les audits.
- Mieux cibler les expériences réellement informatives.
- Mettre en ligne et surveiller plus tôt, pour mesurer sur de vrais usages.

Les progrès que je constate

- Mes premiers projets s'arrêtaient au notebook ; les derniers sont livrés avec API, tests, CI/CD et documentation.
- Je sais diagnostiquer un échec d'entraînement et le corriger, au lieu de relancer au hasard.
- Je présente mes résultats avec leurs limites.
- Je réutilise mon propre code : SortirIA assemble et adapte des briques de cinq projets précédents.
- Un service en ligne, déployé à chaque push, avec évaluation en CI, tableaux de bord, alertes et budget.

Les défis qui restent

- Tenir une charge réelle, au-delà d'un service à faible trafic.
- Orchestrer avec Kubernetes.
- Mesurer la qualité des réponses d'un LLM dans la durée, avec de vrais utilisateurs.
- Travailler en équipe sur un produit IA déjà en production.

ÉVOLUTION DE MA VISION DU MÉTIER

Au début de la formation

Entraîner un bon modèle

↓

Aujourd'hui

Construire un système IA fiable

Je voyais l'AI Engineer comme quelqu'un qui choisit et entraîne des modèles. Je le vois aujourd'hui comme quelqu'un qui part d'un besoin métier, fixe des critères de réussite, construit toute la chaîne (données, modèle, évaluation, service, monitoring) et aide à décider s'il faut déployer ou non.
La formation m'a surtout appris à mener un projet IA comme en entreprise : cadrer le besoin, chiffrer, mesurer, documenter et rendre compte des limites.

```
Données → expérimentation → modèle → évaluation → déploiement → monitoring → amélioration continue
```

SAVOIR-ÊTRE

Soft skills

Esprit d'analyse

Diagnostic de l'échec du premier entraînement sur Qwen3-Base, mesuré puis corrigé (triage médical).

Curiosité et apprentissage continu

Onze projets dans des domaines différents, du scoring crédit au renforcement, aux LLM et au cloud.

Communication et vulgarisation

Documentation publiée pour chaque projet, rapport technique de 20 pages qui s'ouvre sur une synthèse pour les décideurs.

Gestion de projet et autonomie

POC de triage livré en 4 semaines avec une grille go / no-go ; SortirIA en ligne en trois jours, avec une feuille de route jusqu'au gel du code.

Relation client

Des années passées à traduire un besoin client en solution concrète ; pour SortirIA, un circuit prévu pour les lieux partenaires (montré avec des exemples) et des demandes d'autorisation avant toute collecte.

Créativité

Un agent d'échecs qui combine moteur, RAG et LLM, chacun avec un rôle précis.

CONTACT

Construisons quelque chose d'utile.

Vous souhaitez échanger autour d'un projet IA, d'une opportunité ou simplement parler technologie ?

gonzalezcourrier34@gmail.com

© 2026 Stéphane Gonzalez